

UNIVERZA V LJUBLJANI  
FAKULTETA ZA RAČUNALNIŠTVO IN INFORMATIKO

Primož Godec

**Nova podatkovna zbirka in evalvacija  
algoritmov za ocenjevanje razpoloženja  
v glasbi**

DIPLOMSKO DELO  
UNIVERZITETNI ŠTUDIJSKI PROGRAM PRVE STOPNJE  
RAČUNALNIŠTVO IN INFORMATIKA

MENTOR: doc. dr. Matija Marolt

Ljubljana 2014



Rezultati diplomskega dela so intelektualna lastnina avtorja. Za objavljanje ali izkoriščanje rezultatov diplomskega dela je potrebno pisno soglasje avtorja, Fakultete za računalništvo in informatiko ter mentorja

*Besedilo je oblikovano z urejevalnikom besedil L<sup>A</sup>T<sub>E</sub>X.*



Fakulteta za računalništvo in informatiko izdaja naslednjo nalogo:

Tematika naloge:

V diplomskem delu preučite področje ocenjevanja razpoloženja v glasbi. Implementirajte ustrezen spletni vmesnik in pridobite podatke za novo podatkovno zbirko, ki bo vsebovala ocene udeležencev o razpoloženju v glasbi, percepciji barv v glasbi, dojetanju razpoloženskih oznak in barv ter osnovne demografske podatke. Analizirajte dobljeno zbirko in na njeni podlagi primerjajte obstoječe pristope za ocenjevanje razpoloženja v glasbi. Prav tako preučite povezave med ocenjenim razpoloženjem in barvami.



## IZJAVA O AVTORSTVU DIPLOMSKEGA DELA

Spodaj podpisani Primož Godec, z vpisno številko **63110452**, sem avtor diplomskega dela z naslovom:

*Nova podatkovna zbirka in evalvacija algoritmov za ocenjevanje razpoloženja v glasbi*

S svojim podpisom zagotavljam, da:

- sem diplomsko delo izdelal samostojno pod mentorstvom doc. dr. Matije Marolta,
- so elektronska oblika diplomskega dela, naslov (slov., angl.), povzetek (slov., angl.) ter ključne besede (slov., angl.) identični s tiskano obliko diplomskega dela,
- soglašam z javno objavo elektronske oblike diplomskega dela na svetovnem spletu preko univerzitetnega spletnega arhiva.

V Ljubljani, dne 7. septembra 2014

Podpis avtorja:





*Želim se zahvaliti mentorju doc. dr. Matiji Maroltu, za pomoč in spodbudo pri raziskovanju in izdelavi diplomske naloge. Prav tako bi se zahvalil Matevžu Pesku, ki si je vedno vzel čas, ko sem ga potreboval in s spodbujanjem poskrbel, da je bilo diplomsko delo napisano hitreje, kot bi bilo drugače. Zahvalil bi se tudi ekipi s katero smo sodelovali na projektu raziskovanja razpoloženja in glasbe. Ekipo sestavljajo Matevž Pesek, Mojca Poredoš, dr. Jože Guna, dr. Gregor Strle, dr. Emilija Stojmenova, doc. dr. Matija Marolt in doc. dr. Matevž Pogačnik. Zahvala gre tudi moji družini, ki me je podpirala skozi celotno študijsko pot in prijateljem, ki so mi vedno stali ob strani, mi pomagali in poskrbeli, da sem z veseljem hodil na fakulteto: Manca, Petra, Luka, Žiga, Primož, Ožbolt, Rok, Jerneja in Kristina. Zahvalil bi se tudi Mojci Poredoš, ki je pomagala z lektoriranjem naloge.*



Moji družini in prijateljem.



# Kazalo

Povzetek

Abstract

<b>1</b>	<b>Uvod</b>	<b>1</b>
<b>2</b>	<b>Pregled področja</b>	<b>3</b>
2.1	Pridobivanje informacij iz glasbe . . . . .	4
2.2	Ocenjevanje razpoloženja v glasbi . . . . .	6
<b>3</b>	<b>Lastna podatkovna zbirka</b>	<b>13</b>
3.1	Zbiranje podatkovne zbirke . . . . .	13
3.2	Implementacija ankete . . . . .	20
3.3	Sestava podatkovne zbirke . . . . .	20
3.4	Analiza podatkov . . . . .	24
<b>4</b>	<b>Algoritmi za ocenjevanje razpoloženja v glasbi</b>	<b>35</b>
4.1	Regresijski algoritem . . . . .	35
4.2	Essentia Gaiatransform algoritem . . . . .	39
<b>5</b>	<b>Napovedovanje razpoloženja iz barve</b>	<b>47</b>
5.1	Rezultati napovedovanja razpoloženja iz barve . . . . .	48
<b>6</b>	<b>Zaključek in nadaljnje delo</b>	<b>51</b>



# Seznam uporabljenih kratic

<b>SVM</b>	support vector machine	metoda podpornih vektorjev
<b>MIR</b>	music information retrieval	pridobivanje informacij iz glasbe
<b>MIREX</b>	Music Information Retrieval Evaluation eXchange	Letna primerjava rezultatov na področju pridobivanja informacij iz glasbe
<b>VA</b>	Valence-arousal	prijetnost-aktivnost
<b>MIDI</b>	Musical instrument digital interface	standard za opis zvoka z ukazi za proženje zvoka
<b>MFCC</b>	Mel-frequency cepstral coefficients	kepstralni koficient na mel skali
<b>MVC</b>	model, view, controller	model, pogled, kontroler
<b>HSV</b>	hue, saturation, value	odtenek, intenzivnost, svetlost
<b>RGB</b>	red, green, blue	rdeča, zelena, modra





# Povzetek

V diplomskem delu je predstavljena nova podatkovna zbirka, ki vsebuje podatke o razpoloženju za 200 glasbenih odlomkov. Podatkovna zbirka vključuje podatke o razpoloženju, ki je prisotno v glasbi in o razpoloženju, ki ga glasba vzbudi pri udeležencu. Poleg tega vključuje tudi podatke o razpoloženju opisanem z barvo, nekatere demografske podatke in ostale podatke o udeležencu, kot so njegovo trenutno razpoloženje, podatke o udeleženci predstavi razpoloženja glede na prijetnost in aktivnost, glasbeni izobrazbi, najljubše žanre in druge. S spletno anketo smo zbrali več kot 7000 odzivov za 200 glasbenih odlomkov, kar pomeni, da imamo v povprečju 37 odzivov na glasbeni odlomek.

Predstavljena je tudi evalvacijo dveh algoritmov za ocenjevanje razpoloženja iz glasbe. Prvi je regresijski algoritem, ki smo ga uporabili za ocenjevanje prijetnosti in aktivnosti v glasbenem odloku. Drugi je algoritem Gaiatransform, ki glasbo klasificira v pet gruč glede na razpoloženje. Poleg tega ocenjuje tudi verjetnosti, da je v glasbi prisotno eno od šestih razpoloženj. Za zaključek smo analizirali korelacijo med razpoloženjem in barvami v glasbenem odlomku, kar smo naredili z napovedovanjem razpoloženja iz podatka o barvi z uporabo regresijskega algoritma.

**Ključne besede:** glasba, razpoloženje, čustva, algoritem za ocenjevanje razpoloženja



# Abstract

This thesis presents a new dataset of perceived and induced emotions for 200 audio clips. The gathered dataset provides users' perceived and induced emotions for each clip, the association of color, along with demographic and personal data, such as user's emotion state and emotion ratings, genre preference, music experience, among others. With an online survey we collected more than 7000 responses for a dataset of 200 audio excerpts, thus providing about 37 user responses per clip.

The focus of the thesis is the evaluation of classifying emotion states in audio with two existing algorithms. Regression algorithm is used to estimate valence and arousal ratings for audio. The Gaiatransform algorithm is used to classify audi clips in five mood clusters. Gaiatransform algorithm also provide probability of presence for six moods in song. Finally, the regression algorithm was used to analyze possible correlation between colors and mood in valence-arousal space.

**Keywords:** music, mood, emotions, mood clasification algorithms.



# Poglavje 1

## Uvod

Na svetovnem spletu se velikokrat srečamo s priporočilnimi sistemi. Ko poslušamo glasbo, si ogledamo video posnetek ali preberemo članek, nam ti sistemi sami predlagajo vsebine, ki nas bi tudi lahko zanimale. S takimi sistemi se srečujemo na vsakem koraku, malokrat pa se vprašamo, kako pravzaprav delujejo.

Na področju glasbe od priporočilnega sistema pričakujemo, da nam predlaga skladbe, ki bi jih želeli poslušati v danem trenutku. Posledično so najboljši sistemi tisti, ki izbor čim bolj prilagodijo našim željam in potrebam. Večina priporočilnih sistemov na področju glasbe (npr. YouTube, Pandora, Last.fm idr.) deluje na podlagi uporabnikove zgodovine poslušanja, s pomočjo različnih uporabniških oznak in na način, ki ne vključuje postopkov pridobivanja informacij iz glasbe (angl. Music Information Retrieval - MIR). Po drugi strani imajo MIR priporočilni sistemi, ki uporabljajo podatke izračunane iz glasbe, svoje pomanjkljivosti. Splošni pregled literature in področja je pokazal na očitno pomanjkanje javno dostopnih algoritmov, ki bi v priporočanju upoštevali uporabnikovo razpoloženje in čustvene vplive iz glasbe [1, 2, 3].

Razpoloženje je eden izmed temeljnih dejavnikov, ki vplivajo na uporabnikov izbor glasbe v določenem trenutku, po drugi strani pa tudi sama glasba pogosto vpliva na razpoloženje in ga lahko tudi spremeni. Zato je pri izgradnji priporočilnega sistema za glasbo smiselno upoštevati omenjene vidike.

Za raziskovanje algoritmov, ki so uporabljeni v priporočilnih sistemih potre-

bujemo podatkovno zbirko. Na področju razpoloženja trenutno obstaja nekaj podatkovnih zbirk [4, 5, 6, 7, 8], ampak nobena v celoti ne vključuje udeležencevih demografskih podatkov, podatkov o njegovem trenutnem razpoloženju in njegovi predstavi razpoloženja. Prav tako imajo ostale zbirke malo ocen na glasbeni odloimek. Zato smo se odločili, da zberemo svojo podatkovno zbirko. V ta namen smo pripravili spletno anketo. V glavnem delu ankete smo spraševali po razpoloženju v glasbi in o razpoloženju, ki ga glasba vzbudi pri uporabniku. Poleg tega nas je zanimalo še, s kakšno barvo bi uporabnik opisal določeno pesem. Zbirali smo podatke o uporabnikovi predstavi razpoloženja glede na prijetnost in aktivnost. Zanimali so nas še podatki o predstavi barve, njegovem trenutnem razpoloženju in nekateri demografski podatki. Ta zbirka je glede na naše podatke največja tovrstna zbirka na področju razpoloženja.

Pomemben element priporočilnega sistema na podlagi razpoloženja je algoritem, ki zna določiti razpoloženje v glasbi čim bolj natančno. Zaenkrat algoritmi še niso zelo natančni, se pa njihova natančnost iz leta v leto povečuje.

Algoritmi v osnovi delujejo tako, da na podlagi značilnic iz glasbe in podatkov o razpoloženju iz podatkovne zbirke izračunajo določene parametre, s katerimi potem izvajajo ocenjevanje. V ta namen so uporabljeni različni pristopi, kot so metoda podpornih vektorjev, regresija, različna drevesa, naivni bayes in podobni.

V tej nalogi bomo preizkusil več takih sistemov na naši podatkovni zbirki. Pokazali bomo kakšni so rezultati, če uporabimo regresijski algoritem, ki določa prijetnost (valence) in aktivnost (arousal) v glasbi. Prav tako bomo preizkusili algoritem, ki za svojo osnovo uporablja SVM in na podlagi tega določi eno od petih razpoloženskih gruč, ki so uporabljene tudi na MIREX (Music Information Retrieval eXchange) opravilu.

V naslednjem poglavju bomo pregledali področje, ki ga obsega ta diplomatska naloga. V poglavju 3 bomo bolj natančno predstavili zbiranje naše podatkovne zbirke in naredil krajšo analizo podatkov v njej. V četrtem poglavju bomo predstavili, kako delujejo različni algoritmi za določanje razpoloženja v glasbi in predstavil rezultate, ki jih dobimo, če te algoritme uporabimo na naši podatkovni zbirki. V zadnjem poglavju bomo predstavili regresijski algoritem za ocenjevanje razpoloženja iz glasbe in rezultate ocenjevanja s tem algoritmom.

# Poglavje 2

## Pregled področja

Lahko bi rekli, da je glasba ena najstarejših in zelo pomembnih aktivnosti na svetu. Razširjena je po celem svetu, poznajo jo tudi izolirana in od ostalega sveta odmaknjena plemena. Znano je, da glasba na svetu obstaja že vsaj 50 000 let [9]. Prvo glasbo naj bi takrat izvajali na afriških tleh. Nato se je skozi čas razvijala in postala ena najpomembnejših sestavnih delov človekovega življenja. O pomembnosti glasbe priča dejstvo, da jo lahko slišimo praktično na vsakem koraku. Poslušamo jo doma, na poti, ko nam je dolgčas ali ko se želimo razvedriti, poslušamo jo, ko smo na kavi ali v trgovini. Ponekod s pravo izbiro glasbe vplivajo na človekove odločitve. Na primer, v trgovinah in lokalih z glasbo privlačijo kupce. Vse to priča o pomembnem vplivu glasbe na človeka.

Glasba pomembno vpliva na človekova čustva in razpoloženje. To moč ima predvsem zaradi tega, ker ima neposredno pot do čustev. Glasbo namreč doživljamo z notranjimi čuti, zato ni potrebne predhodne interpretacije, kot je potrebna pri razumevanju tiskane besede. Znano je, da različna glasba vzbudi različna čustva in ima moč, da vzbudi potlačena čustva. Na vzdušje vpliva razmerje med toni. Mol pričara bolj melanholično vzdušje, dur pa bolj veselo [10].

V nadaljevanju poglavja bomo povedali še nekaj o področju, imenovanem pridobivanje informacij iz glasbe. To področje je pomembno, saj je osnova za temo diplomske naloge. Povedali bomo nekaj o povezavi med razpoloženjem in glasbo. Pregledali bomo podatkovne zbirke, ki obstajajo trenutno na področju razpoloženja

in glasbe. Za konec pa bomo predstavili še algoritme za ocenjevanje razpoložnja iz glasbe.

## 2.1 Pridobivanje informacij iz glasbe

Pridobivanje informacij iz glasbe (MIR) je interdisciplinarna znanost, ki povezuje predvsem muzikologijo in računalništvo [11]. Vključuje tudi področja kot so psihologija, procesiranje signalov in strojno učenje.

To področje je dokaj novo in se trenutno hitro širi. Področje se je začelo razvijati v osemdesetih letih prejšnjega stoletja in je močno povezano z razvojem računalništva. Šele v 21. stoletju je, predvsem zaradi povečanih računskih zmognosti računalnikov, doživelo razcvet. Pojavljajo se velike razlike v načinu obdelave in uporabe podatkov. Prav tako so cilji raziskovalcev zelo različni. Pomembni cilji v MIR so: narediti dober algoritem za ocenjevanje razpoložnja in žanrov iz glasbe, dobro ocenjevati akorde in izboljšati algoritme za transkripcijo glasbe v simbolično obliko.

Ključni namen področja je pridobiti informacije iz glasbe in jih uporabiti. Poznamo več vrst informacij. Lahko so pridobljene direktno iz zapisa glasbe ali simboličnega zapisa, lahko pa so metapodatki, ki so pridobljeni na drug način. Rezultati služijo za različna opravila.

Relevantno in nepristransko ovrednotenje različnih opravil omogoča Pobuda o skupni evalvaciji pri pridobivanju informacij iz glasbe (angl. Music Information Retrieval Evaluation eXchange - MIREX) [12, 13]. MIREX formalizira opravila s področja MIR in postopke za evalvacijo algoritmov, ki ta opravila rešujejo. V nadaljevanju bomo predstavili opravila, kjer trenutno poteka največ raziskovalnega dela.

### **Priporočilni sistemi za glasbo (Music Recommendation Systems)**

Trenutno obstaja veliko takih sistemov [2, 14], kot so YouTube, Pandora, iTunes, Spotify in Last.fm, ampak samo nekateri uporabljajo informacije pridobljene z MIR za svoje delovanje. Namesto tega veliko sistemov uporablja informacije na podlagi primerjave med zgodovinami poslušanja uporabnikov. Na primer, sistem predlaga glasbo, ki so jo poslušali uporabniki s podobno zgodovino poslušanja. Drugi



spet uporabljajo oznake k določeni glasbi ali druge informacije, ki niso del MIR-a. Te oznake lahko dodajo uporabniki ali strokovnjaki. Pri sistemu Pandora glasbo označujejo strokovnjaki, pri sistemu Last.fm [15] pa uporabljajo oznake dodane s strani uporabnikov. Oznake, ki se uporabljajo, so lahko različne. Lahko označijo zvrst glasbe (npr. rock, pop, ...), opisujejo razpoloženje (vesel, žalosten, sproščen, ...), povejo ali je pesem instrumentalno izvedena ali vsebuje vokal, je ta vokal ženski ali moški in podobno. Od kar se je področje MIR zelo razširilo vedno več priporočilnih sistemov uporablja informacije pridobljene iz glasbe.

**Ločevanje pesmi na več izvorov in prepoznavanje inštrumentov** Algoritmi za ločevanje pesmi poizkuša pesem, v kateri nastopa več instrumentov in vokali, razstaviti tako, da imamo posamezne izvore v pesmi ločene. Na primer, lahko loči glede na instrumente, za kar potrebuje algoritem za prepoznavanje instrumentov. V tem primeru je algoritem za prepoznavanje instrumentov lahko del algoritma za ločevanje pesmi.

Na tem področju obstaja že kar nekaj algoritmov [16, 17]. Algoritmi se uporabljajo za ločevanje posameznega inštrumenta iz glasbe, kar pride prav pri izključevanju posameznih instrumentov iz podlage. Na tak način lahko izključimo tudi vokal iz glasbe, kar je uporabljeno pri algoritmih za pripravo pesmi za karaoke. Pri algoritmih za izključevanje vokala iz glasbe je še veliko možnosti za izboljšave. Algoritmi težje ločijo vokal, ker notri nastopajo določene frekvence, ki se pojavijo tudi pri določenih inštrumentih.

**Avtomatična transkripcija glasbe** Ti pristopi delujejo tako, da glasbo iz posnetka pretvarjajo v simbolični zapis [18, 19, 20]. Najpogosteje je to uporabljeno pri prepisovanju glasbe v zapis MIDI [21]. Rešitve za transkripcijo vključujejo številne algoritme: zaznavanje pojavitve glasbenih dogodkov (onset detection), ocenjevanje trajanja, identifikacijo instrumentov, prepoznavanje ritma in ostale. Rešitve, ki trenutno obstajajo še niso popolne. Kompleksnost transkripcije nastane, ko je v pesmi veliko inštrumentov in večja polifonija (nastopa več sočasnih zvokov).

**Avtomatična kategorizacija glasbe** To so pristopi, ki znajo razvrstiti glasbo v več v naprej definiranih skupin. Na področju MIR se raziskovalci trenutno

ukvarjajo predvsem s kategorizacijo po žanrih in razpoloženju v glasbi. Za obe temi MIREX organizira opravilo v kategorizaciji glasbe. Raziskovalci lahko oddajo svoj algoritem, ki ga potem poženejo na MIREX-ovi podatkovni zbirki. Za kategorizacijo se uporabljajo tehnike strojnega učenja, kot so SVM [22], regresija, različna drevesa in druge.

## 2.2 Ocenjevanje razpoloženja v glasbi

Eno pomembnih področij v MIR je ocenjevanje razpoloženja v glasbi s pomočjo računalniških algoritmov. Algoritmi deluje s strojnim učenjem na podlagi značilnic izračunanih iz zvočnih posnetkov. Za učenje algoritmov potrebujemo podatkovno zbirko z ocenjenim razpoloženjem.

Ti algoritmi v osnovi delujejo tako, da najprej iz zvočnega zapisa izračunajo značilnice. V naslednjem koraku se na podlagi že obstoječe podatkovne zbirke nauči algoritem. Nato se izvede klasifikacija na glasbeni zbirki, ki jo želimo klasificirati. Za učenje teh algoritmov potrebujemo podatkovno zbirko z že obstoječimi podatki o razpoloženju, zato bomo v naslednjem podpoglavju opisali, kaj na tem področju že obstaja. Poleg tega bomo naredili še pregled obstoječih algoritmov.

### 2.2.1 Podatkovne zbirke

Na področju razpoloženja v MIR obstaja nekaj podatkovnih zbirk, ki vsebujejo različne razpoloženjske oznake za glasbo.

**Podatkovna zbirka s filmsko glasbo** Eerola et. al [4] so zbrali podatkovno zbirko, ki vključuje filmsko glasbo iz različnih filmov. Ta podatkovna zbirka je razdeljena na dva dela. Prvi del podatkovne zbirke vsebuje 361 glasbenih odlomkov. Za vsak odlomek je v podatkovni zbirki povprečno vrednost za prijetnost (ang. valence), aktivnost (ang. arousal) in napetost (ang. tension). Poleg tega so za vsako pesem zbrali tudi oznake za razpoloženje (vesel, žalosten, nežen in podobne). K vsakemu odlomku je dodana tudi povprečna številčna vrednost o prisotnosti posameznega razpoloženja izmed nabora razpoloženj: jeza, strah, veselje, žalost in nežnost. Drugi del zbirke vsebuje 110 glasbenih odlomkov, ki so podmnožica odlomkov iz prvega

dela. Poleg vseh oznak, ki jih ima prvi del ima ta del dodane številčne vrednosti, ki označujejo prisotnost za občutji lepota (beauty) in naklonjenost (liking). Ta podatkovna zbirka poleg podatkov vsebuje tudi glasbene odlomke, ki so dolgi 15 sekund, kar je dobro za evalvacijo podatkovne zbirke na različnih algoritmih. Podatkovna zbirka vsebuje še podatke o naslovu filma za posamezen odlomek in podatek iz katerega dela pesmi je bil odrezan.

**Mood Swing Turk Dataset** Podatkovna zbirka Mood Swing Turk Dataset [5] je bila zbrana za 240 glasbenih odlomkov popularne glasbe. Vsak odlomek vsebuje povprečno 17 vrednosti, ki opisujejo prijetnost (valence) in aktivnost (arousal). Dodani so še podatki o glasbi (naslov, avtor, album) in tudi podatki o poteku ocenjevanja (krog ocenjevanja, v katerem so bile zbrane ocene in identifikacijska številka uporabnika, ki je podal posamezno oceno).

Sama podatkovna zbirka ne vsebuje uporabljenih glasbenih odlomkov, so pa zaradi tega objavljene že izračunane značilnice za posamezno pesem. Podatkovna zbirka vsebuje naslednje značilnice: Mel-frequency cepstral coefficients (MFCCs), Octave-Based Spectral Contrast, Statistical Spectrum Descriptors (SSDs), Chromagram in EchoNest Audio Features.

**Cal500** Podatkovna zbirka Cal500 [6] ima zbrane podatke o razpoloženju za 500 pesmi. Pesmi so zbrane med zahodno popularno glasbo. Za vsako pesem vsebuje oznako za razpoloženje (vesela, žalostna, jezna in podobne). V naboru je na voljo 18 možnih oznak. Podatkovna zbirka je bila označena ročno in prikazuje 3 oznake na pesem. Vsebuje tudi datoteke z glasbo v MP3 obliki.

**MTV Music Dataset** MTV Music Dataset [7] vsebuje podatke za 192 pesmi izbrane iz MTV Europe Most Wanted lestvic med leti 1981 in 2000. Celotna podatkovna zbirka je bila označena s strani petih ocenjevalcev. Vsaka ocena vsebuje vrednost za prijetnost (valence) in vrednost za aktivnost (arousal). Posamezna pesem je bila označena s strani treh ocenjevalcev.

**LAMP** Podatkovna zbirka LAMP [23] vsebuje podatke za 492 popularnih pesmi izdanih med 2002 in 2008. Ta zbirka je bila označena s strani 400 udeležencev v

treh korakih. V prvem je udeleženec dobil samo besedilo in na podlagi tega določil prijetnost (valence) in aktivnost (arousal). V drugem koraku je dobil samo zvočni posnetek ter določal aktivnost in prijetnost. V tretjem koraku je postopek ponovil z zvočnim posnetkom in besedilom.

**Multi Modal** Zadnja zbirka, ki jo bom opisal je tako imenovana Multi Modal [8] podatkovna zbirka. Vsebuje 903 glasbene odlomke, ki so dodani podatkovni zbirki. Vključena je večinoma popularna zahodna glasba. Za vsako pesem je določena oznaka z razpoloženjem iz nabora: boisterous, confident, passionate, rousing, rowdy, amiable-good natured, cheerful, fun, rollicking, sweet, autumnal, bittersweet, brooding, literate, poignant, wistful, campy, humorous, silly, whimsical, witty, wry, aggressive, fiery, intense, tense - anxious in visceral. Poleg tega je tudi vsaka razvrščena v eno od petih gruč definiranih s strani MIREX-a (gruče so predstavljene v poglavju 2.2.2).

### 2.2.2 Algoritmi za ocenjevanje razpoloženja v glasbi

Vsi algoritmi za ocenjevanje razpoloženja iz glasbe potrebujejo za učenje svojih parametrov podatkovno zbirko, zato smo se v prejšnjem poglavju posvetili pregledu področja obstoječih zbirk. Algoritmi izvedejo klasifikacijo v VA prostor ali katero drugo kategorijo na podlagi značilnic izračunanih iz glasbe. Značilnice so opisane v poglavju 2.2. VA prostor (ang. valence-arousal space) je dvodimenzionalni prostor, ki je določen z prijetnostjo (prva dimenzija) in aktivnostjo (druga dimenzija).

Delovanje algoritmov za ocenjevanje razpoloženja v glasbi delimo na dva dela. Prvi del je učenje algoritma, v drugem delu pa z algoritmom izvedemo klasifikacijo. Učenje poteka tako, da uporabimo eno izmed metod strojnega učenja. Na podlagi značilnic in podatkov o razpoloženju iz podatkovne zbirke algoritem izračuna pravilo za klasifikacijo. Ta postopek se izvaja na delu podatkovne zbirke namenjene učenju algoritma. Z naučenim algoritmom izvedemo klasifikacijo na preostanku podatkovne zbirke. Rezultat, ki ga vrne algoritem, je lahko skupina po razpoloženju, v katero uvrstimo določeno pesem ali pa številčna vrednost, ki določa le prijetnost in aktivnost.

To je splošen postopek klasifikacije. Vsak algoritem ima svoje posebnosti. Obstoječi algoritmi so opisani v nadaljevanju.

Schmidt et. al [24] so uporabili regresijski algoritem (metoda najmanjših kvadratov) za klasifikacijo. Podatkovno zbirko so razdelili na dva dela tako, da so 70% podatkovne zbirke uporabili za učenje algoritma in 30% za testiranje. Za značilnice so uporabili mel-frequency cepstrum coefficients in kromatski vektor. Algoritem napoveduje prijetnost (valence) in aktivnost (arousal) pesmi. Parametra algoritma ocenjuje ločeno.

Panda et al. [8] so uporabili več algoritmov za ocenjevanje in primerjali točnost ocenjevanja. Uporabili so: metodo podpornih vektorjev, k-nearest neighbours, C4.5 in naivni bayes. Algoritem izvaja klasifikacijo na podlagi 19 značilnic izračunanih iz glasbenega posnetka. Tem značilnicam so dodali tudi značilnice pridobljene iz MIDI signala in značilnice iz besedil. Izvajali so klasifikacijo v pet gruč, ki so definirane za MIREX opravilo (tabela 2.1). Kot najboljši algoritem se je izkazal SVM. Na podlagi značilnic iz zvočnega zapisa je dosegel natančnost 64%. Ko so bile dodane še značilnice iz MIDI zapisa in besedil, se je natančnost zmanjšala na 61.1%. Algoritem so preizkusili na podatkovni zbirki s 903 pesmimi.

Laurier et. al [25] so za ocenjevanje uporabili metodo podpornih vektorjev [22]. Algoritem za delovanje uporablja 133 značilnic. Tudi ta algoritem deluje tako, da kot rezultat za vsako pesem vrne eno od petih gruč opisanih v tabeli 2.1. Preizkusili so več različnih SVM metod in ugotovili, da najboljše rezultate vrača metoda C-SVC z RBF (radial basis function) jedrom iz SVMlib knjižnice.

Diane Watson [26] je uporabila klasifikator z Bayesovimi mrežami in ocenjevanje z markovskimi verigami. Kot rezultat je algoritem napovedoval prijetnost (valence) in aktivnost (arousal). Za razliko od ostalih je uporabila podatke, ki niso bili zajeti v laboratorijskem okolju temveč v vsakdanjem življenju. Uporabniki so skladbe ocenjevali s pomočjo pametnih telefonov, kjerkoli so se nahajali v trenutku, ko jih je aplikacija prosila za oceno. Poleg značilnic iz glasbe je algoritem upošteval tudi podatke o tem, kako prijetno se uporabnik počuti v času ocenjevanja in podatke o njegovi aktivnosti ter še nekatere druge podatke o stanju in okolju med tem ko je ocenjeval. Algoritem je dosegel natančnost 67% za aktivnost (arousal) in 75% za prijetnost (valence).

Saari et. al [15] so uporabili semantic layer projection (SLP) metodo za klasifikacijo. Za klasifikacijo so uporabili značilnice, končni rezultat pa so oznake z razpoloženji. Za razliko od prej opisnih metod, ki klasifikacijo izvedejo v enem koraku, je tu drugače. Tukaj najprej preslikajo značilnice v tri dimenzionalni prostor z uporabo metode delnih najmanjših kvadratov (partial least squares - PLS). V drugem koraku na podlagi teh vrednosti določijo razpoloženje. Algoritem so poskusili tudi v kombinaciji z tekstovnimi oznakami, vendar je deloval slabše.

Tabela 2.1: Gruče razpoloženj, ki se uporabljajo v MIREX mood opraviu

Gruče	Razpoloženja
Gruča 1	strastno, vznemirjeno, razposajeno
Gruča 2	veselo, zabavno, prijetno, ljubeznivo
Gruča 3	ganljivo, bridko, potrto, otožno, grenko-sladko, malodušno
Gruča 4	šaljivo, duhovito, smešno, neumno, čudaško, muhasto
Gruča 5	agresivno, nasilno, ognjevito, razdražljivo, napeto, intenzivno, nestanovitno, spreminjajoče

### 2.2.3 Značilnice

Značilnice razdelimo v skupine po podobnosti. Eno od takih razporeditev, povzeto po [25, 27], bomo predstavili v nadaljevanju. Značilnice so povzete v tabeli 2.2.

- **Spektralne značilnice** se nanašajo na obliko spektra v glasbi. Izmed teh značilnic se na področju MIR veliko uporabljajo MFCC, HFC (high frequency content), kromatski vektor, spektralni močnostni vrh (spectral strong peak), GFCC (gammatone feature cepstrum coefficients) in podobne. MFCC (mel-frequency cepstral coefficients) [28] so značilnice, ki predstavljajo obliko frekvenčnega spektra. Temeljijo na linearni kosinusni transformaciji logaritmičnega močnostnega spektra na nelinearni Mel frekvenčni skali. Spectral strong peak [29] nam pove ali spekter vključuje izrazit vrh. Vrednost je večja, če je vrh višji in tanjši. HFC je izračunan na podlagi spektra in označuje količino visokih frekvenc v signalu [30].

- **Časovne značilnice** se nanašajo na časovne spremembe v signalu in trajanje nekega stanja v signalu. Efektivno trajanje (effective duration) nam pove, koliko časa je bil signal nad določeno energijo. ZCR (zero-crossing rate) [31] je vrednost, ki nam pove, kolikokrat je signal prešel iz pozitivne vrednosti v negativno in obratno. Leq, LARM, loudness so različne mere za glasnost.
- Med **tonskimi značilnicami** je pomembna tonaliteta [32], ki je skupina vseh karakteristik, ki povezujejo niz tonov ali akordov neke tonalne kompozicije okrog tonike, t.j. okrog središča tonalitete. Kosonanca (consonance) [33] je definirana s frekvenčnimi razmerji. Nanaša se na akorde, harmonijo ali intervale, ki jih obravnavamo kot stabilne, ter nam izzovejo občutje ugodja. Ravno nasprotje kosonanci je disonanca (dissonance). Ta na poslušalca deluje neugodno in se odraža z negativno psihofizično reakcijo. Harmonični ritem (harmonic rhythm) [34] je razmerje, ki pove kako se akordi spreminjajo v sestavi glasbe. Poleg teh se uporablja tudi histogram akordov (chord histogram) in ostali.
- **Ritmične značilnice** Zelo pomembna značilnica v tem sklopu je število ritmičnih enot na minuto (BMP - beats per minute). To je značilnica, ki nam opisuje tempo v glasbi. Ker se v večini pesmi skozi čas BMP spreminja, je pomembna enota tudi BMP histogram. Uporablja se tudi BeatLoudnes, ki predstavlja glasnost signala v oknu okoli udarca.
- **Visoko nivojske značilnice v glasbi** so bolj abstraktne in med seboj zelo različne. To so značilnice, ki jih v večini ocenjujemo na podlagi ostalih značilnic opisanih zgoraj. Gre za značilnice kot so razpoloženje, žanri, barva glasu in ostale.

Tabela 2.2: Pogosto uporabljene značilnice za ocenjevanje čustev iz glasbe

Skupina	Značilnice
Spektralne značilnice	MFCC, HFC, kromatski vektor, spektralni močnostni vrh, GFCC
Časovne značilnice	efektivno trajanje, ZRC, leq, LARM, loudness
Tonske značilnice	tonaliteta, kosonanca, disonanca, harmonični ritem, histogram akordov
Ritmične značilnice	BPM, BPM histogram, beat loudness
Visoko nivojske značilnice	žanri, barva glasu, razpoloženje



## Poglavje 3

# Lastna podatkovna zbirka

Tema moje diplomske naloge je ocenjevanje razpoloženja v glasbi s pomočjo računalniških algoritmov. Dobrega algoritma za ocenjevanje ni možno narediti brez dobre podatkovne zbirke. Na področju razpoloženja obstaja že nekaj podatkovnih zbirk, vendar nobena ne vključuje dodatnih povezav, kot je povezava med glasbo in barvo ali podatkov o predstavi razpoloženja v VA prostoru in z barvo. Zaradi tega smo se odločili, da zberemo svojo podatkovno zbirko, ki bo osnova za raziskovanje povezave med razpoloženjem in glasbo. Vključevala bo tudi podatke o barvah, ki po mnenju udeležencev najbolje opisujejo posamezno pesem, uporabnikovo percepcijo povezave med glasbo, barvami in razpoloženjem ter nekatere demografske podatke.

V tem poglavju bomo opisali, kako smo zbirali podatke, namenil nekaj besed preliminarni analizi, ki smo jo opravili na krajši anketi. Opisali bomo glavno anketo, s katero smo zbirali podatke, ki sestavljajo podatkovno zbirko. Za konec bomo opisali še, kaj sestavlja podatkovno zbirko in podatke analizirali.

### 3.1 Zbiranje podatkovne zbirke

Podatkovno zbirko smo zbirali s spletno anketo, ki smo jo implementirali sami. Pred oblikovanjem glavne ankete, smo morali sprejeti še nekaj odločitev o tem, kako zgraditi anketo, da bo dala dobre in smiselne rezultate. Prva stvar, kjer je bil potreben premislek, je izbor razpoloženskih oznak. Ugotovili smo, da obstajajo

nekatero osnovne oznake za razpoloženja, na primer [35]. Zaradi subjektivne narave področja ni standardnega seta oznak, ki bi se uporabljale na področju povezanem z razpoloženjem in glasbo. Nekateri avtorji so izbrali zbirko oznak čisto intuitivno, na primer Wu et al. [36]. V izogib subjektivnosti smo se odločili, da naredimo preliminarno raziskavo v obliki ankete, v kateri smo preverjali smiselnost oznak.

### 3.1.1 Preliminarna analiza

Kot omenjeno, smo preliminarno analizo izvajali s pomočjo ankete, ki smo jo izvedli v elektronski obliki. Želeli smo preveriti smiselnost oznak, primernost elementov ankete in ugotoviti, katere oznake za razpoloženja so tista, ki bodo uporabljena v glavni anketi. Razpoloženja smo izbirali tako, da je moral uporabnik za 46 razpoloženjskih oznak označiti, v kolikšni meri je neko razpoloženje pri njem prisotno v tistem trenutku. Uporabnik je to označil na skali od 1 do 7, prikazani na sliki 3.1. Metoda glavnih komponent na podatkih, zbranih na tak način, je pokazala, da prve tri dimenzije razložijo 64% variance v podatkovni zbirki. Te tri komponente močno korelirajo s sedemnajstimi razpoloženjskimi oznakami, ki smo jih izbrali iz nabora omenjenih 46 oznak: aktivno, budno, dremavo, neaktivno, nesrečno, nezadovoljno, razočarano, sproščeno, srečno, utrujeno, vedro, veselo, zadovoljno, zaspano, žalostno, mirno in ježno.

Zanimala nas je tudi struktura vprašalnika, ki je ostala približno enaka v glavnem vprašalniku, s to razliko, da smo tam dodali del z glasbenimi odlomki. Več o tem v poglavju 3.1.2.

Poleg tega smo testirali tudi elemente uporabljene v anketi (sedem stopenjska skala, neskončni barvni krog, izbira z izbirnimi gumbi (radio buttons) in tekstovnimi polji). Ugotovili smo, da moramo nekatere elemente spremeniti. Spremenili smo barvno skalo, tako da smo jo omejili na barvni krog z 49 možnostmi izbire. To je bilo potrebno, ker je imel uporabnik na neskončni skali preveliko možnost izbiranja, obenem pa je bil sistem tri dimenzionalen, kar večina uporabnikov ni opazila in so nastavljali samo odtenek barve, na svetlost in nasičenost pa so pozabili. Skala z 49 možnostmi (prikazana na sliki 3.2) se je izkazala kot boljša alternativa, saj še vedno ponuja veliko možnosti izbire barv in je prijazna uporabniku, pridobljeni podatki so



Slika 3.1: Del sedem stopenjske lestvice, s pomočjo katere so udeleženci ocenjevali trenutno razpoloženje. Oznaka 1 pomeni, da se tisto razpoloženje pri udeležencu sploh ne pojavi, 7 pa da je zelo izrazito.


boljši.

Poleg zamenjave barvnega kroga smo zamenjali tudi nekaj ostalih elementov. V delu, kjer uporabnik označi tri svoje najljubše žanre, smo se odločili namesto vpisnih polj ponuditi uporabniku seznam 20 žanrov, iz katerega je izbral in potegnil svoje tri izbire na nov seznam. Za to smo se odločili, ker so uporabniki v preliminarni analizi v prostor vpisovali tudi žanre, ki niso osnovni in oznake, ki sploh niso žanri. Prav tako nam je preliminarni vprašalnik pomagal izbrati, kateri žanri so tisti, ki jih bomo uporabniku ponudili. Zamenjali smo tudi način, kako uporabnik vnese svoje trenutno razpoloženje in za ta namen uporabili nov element MoodGraph, ki ga bomo opisali v poglavju 3.1.2.

### 3.1.2 Glavna anketa

Glavni vprašalnik, s katerim smo zbrali našo podatkovno zbirko, je bil implementiran na podlagi preliminarne analize, saj smo v skladu z zbranimi podatki prilagodili oznake in strukturo vprašalnika. Glavni vprašalnik je bil sestavljen iz treh delov.

**Prvi del** ankete je bil namenjen zajemanju podatkov o udeležencevi starosti, spolu, o tem, ali živi na podeželju, ali v mestu, glasbeni izobrazbi, najljubših žanrih



Slika 3.2: Barvni krog na levi smo uporabili v preliminarni anketi. V zunanjem krogu je bilo možno izbrati odtenek (hue) v notranjem pa je bilo možno izbirati nasičenost in svetlost. Desni krog smo uporabili v glavni anketi. Krog je omogoča izbiro med 49 barvami. Rezina predstavlja en barvni odtenek, proti notranjosti pa se spreminja svetlost in intenzivnost.

in poslušanju glasbe. Uporabnika smo vprašali tudi, če je pod vplivom drog ali drugih substanc.

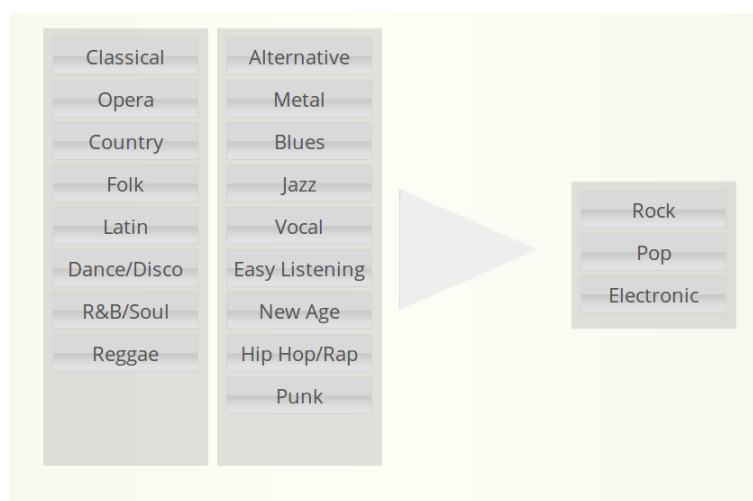
**Drugi del** je bil namenjen ocenjevanju udeleženčevega trenutnega razpoloženja, njegove percepcije oznak za razpoloženje in barve za razpoloženje. Te podatke zajemamo zato, ker nam omogočajo, da ugotovimo povezave med različnimi ocenami razpoloženja v tretjem delu, ki vključuje glasbene odlomke.

V **tretjem delu** smo želeli, da udeleženci za 10 glasbenih odlomkov dolgih 15 sekund označijo razpoloženje, ki ga zaznavajo pri glasbi (perceived) in tistega, ki občutijo (induced) ter razpoloženje opišejo z barvo. Odlomki so bili naključno izbrani iz nabora 200 odlomkov. Ker smo se želeli izogniti pristranskosti uporabnika zaradi poznavanja določene glasbe ali dogodkov, ki so se mu zgodili ob poslušanju določene pesmi, smo odlomke izbrali iz zbirk, ki vsebujejo uporabnikom nepoznano glasbo (Jamendo, zbirka s filmsko glasbo, zbirka slovenskih ljudskih pesmi in zbirka elektro-akustične glasbe).

Glasba je bila izbrana iz štirih različnih virov. Iz odprte podatkovne zbirke Jamendo smo izbrali 80 pesmi, ki so bile iz različnih žanrov in bolj vsakdanje. Na-

slednjih 80 pesmi smo vzeli iz zbirke filmske glasbe opisane v [4]. Dodali smo še 20 slovenskih ljudskih pesmi in 20 pesmi iz nabora elektro-akustične glasbe. Uporabnikov nismo želeli preveč obremeniti, zato je bilo vsakemu uporabniku naključno dodeljenih zgolj 10 odlomkov.

V anketi smo poleg običajnih elementov, kot so spustni sezname in izbirnimi gumbi, uporabili elemente, ki smo jih načrtovali sami. Prvi element je **element za izbiro najljubših žanrov**. Uporabnik je moral v elementu na sliki 3.3 izmed 20 žanrov v stolpcih na levi, izbrati do tri svoje najljubše žanre in jih razporediti po priljubljenosti v desni stolpec.



Slika 3.3: Element v anketi uporabljen za izbiro najljubših žanrov. Anketiranec je iz levih dveh stolpcev v desnega potegnil do tri izbrane žanre in jih razvrstil po priljubljenosti.

Drugi element, ki smo ga načrtovali je **barvni krog**, ki smo ga že opisali v poglavju 3.1.1 in je bil namenjen zajemanju podatka o razpoloženju, opisanem z barvo.

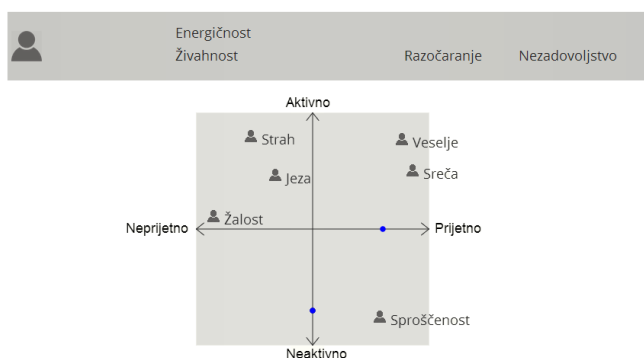
Udeleženec je prisotnost posameznega razpoloženja ocenjeval z elementom imenovanim **MoodStripe** (slika 3.4). Posamezno oznako razpoloženja je potegnil v prostor, kjer od leve proti desni narašča prisotnost posameznega razpoloženja. Če je udeleženec postavil razpoloženje skrajno levo, to pomeni, da to razpoloženje pri

njem ni prisotno, če ga je postavil skrajno desno, to pomeni, da je razpoloženje zelo prisotno.

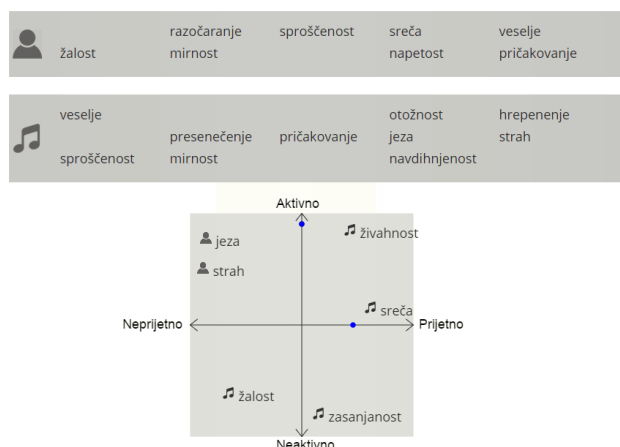


Slika 3.4: Element za zajemanje pristnosti posameznega razpoloženja imenovan MoodStripe. Udeleženec je iz zgornjega pravokotnika povlekel razpoloženja in jih vstavil na ustrezno mesto na traku glede na prisotnost posameznega razpoloženja. Prisotnost narašča iz leve (razpoloženje ni izrazito) proti desni (razpoloženje je zelo izrazito).

Uporabili smo tudi element **MoodGraph**. Uporabnik je s pomočjo tega elementa postavil razpoloženje v valence-arousal (VA) prostor [37]. To je prostor, kjer od leve proti desni narašča prijetnost, od spodaj navzgor pa aktivnost. Element smo načrtovali v dveh izvedbah. Prvi je eno nivojski MoodGraph, predstavljen na sliki 3.5. Uporabili smo ga za ocenjevanje prijetnosti in aktivnosti posameznih razpoloženj v drugem delu ankete. Uporabnik je razpoloženja iz prostora nad grafom povlekel na ustrezno mesto v VA prostor. Drugi je dvo nivojski MoodGraph (slika 3.6). Uporabili smo ga za označevanje razpoloženj, ki nastopajo v glasbenem odlomku in uvrstitev teh v VA prostor. Uporabnik je razpoloženja izražena v odlomku izbiral iz nabora 14 oznak (označenih z ikono osebe), razpoloženja, ki jih je glasba pri njem vzbudila (označena z noto), pa iz nabora 10 oznak. Iz vsakega nabora je moral izbrati in v VA prostor uvrstiti najmanj eno razpoloženje.



Slika 3.5: Enonivojski MoodGraph, element za zajemanje precepcije razpoloženja v VA prostoru. Udeleženec je razpoloženske oznake uvrstil v graf glede na prijetnost in aktivnost. Prijetnost narašča iz leve proti desni. Aktivnost narašča od spodaj navzgor.



Slika 3.6: Dvonivojski MoodGraph, element za zajemanje razpoloženja v glasbi in njegovo umestitev v VA prostor. Nota označuje nabor razpoloženj, ki jih udeleženec zazna v glasbi (perceived). Figura človeka označuje nabor razpoloženj, ki jih udeleženec občuti (induced). Udeleženec je iz vsake skupine razpoloženj izbral tista, ki po njegovem izražene ali vzbujene in jih umestil na v VA prostor glede na prijetnost in aktivnost.

## 3.2 Implementacija ankete

Anketo smo implementirali v obliki spletne aplikacije. Za osnovo spletne aplikacije smo izbrali okolje CodeIgniter. Gre za odprto kodno okolje, ki je namenjeno za izdelavo spletnih aplikacij. Narejen je na osnovi jezika PHP in uporablja princip MVC (model-view-controller). Princip MVC pomeni, da je aplikacija razdeljena v tri dele. Model skrbi za povezavo s podatkovno bazo, view skrbi za prikaz podatkov uporabniku, med tem ko controller upravlja s podatki in skrbi za delovanje aplikacije.

Za implementacijo same ankete smo uporabili tehnologije HTML5, javascript, jQuery in xml. Anketa je sestavljena tako, da se dinamično generira na podlagi podatkov iz xml dokumenta. Na tak način smo naredili okolje, kjer za kreiranje nove ali popravljanje obstoječe ankete ni potrebno ročno sestavljati html dokumenta. Zaradi takega načina implementacije bo sistem možno uporabiti še za druge ankete, saj je zelo splošen. Elementi ankete se dinamično generirajo s pomočjo javascript skripte, ki uporablja tudi elemente jQuerya. Anketa poleg klasičnih tekstovnih polj, izbirnih gumbov in izbirnih seznamov vsebuje tudi elemente, ki smo jih načrtovali sami. Element za izbiro najljubšega žanra, MoodGraph in MoodStripe, predstavljeni v poglavju 3.1.2, so načrtovani z uporabo HTML5 canvasa in jQuery draggable funkcionalnosti. Prav tako je na podlagi HTML5 canvasa in jQuery poslušalcev za klik načrtovan element za izbiro barv.

Za preverjanje pravilnosti vnosa smo uporabljali HTML5 funkcionalnost za klasične elemente (vnosno polje, izbirni seznam in izbirni gumbi) in preverjanje z uporabo javascript skripte za elemente, ki smo jih načrtovali sami (MoodGraph, MoodStripe, element za izbiro žanra in element za izbiro barve). Rezultate smo shranjevali v podatkovno bazo MySQL z uporabo funkcij, ki jih prinaša model v CodeIgniterju.

## 3.3 Sestava podatkovne zbirke

Struktura podatkovne zbirke sledi strukturi uporabljene ankete, zato je razdeljena v tri dele. V prvem delu smo zbrali 1423 odgovorov in s tem tudi toliko vpisov v našo zbirko. V drugem delu je vpisov 1090. V tretjem delu, kjer je moral udeleženec oceniti 10 pesmi, smo zbrali 7187 odgovorov. Ta del je izpolnjevalo 741 udeležencev.



V prvem delu so podatki, ki opisujejo udeležence (podrobnosti so predstavljene v tabeli 3.1). Za vsakega udeleženca zbirka vsebuje podatek o starosti na leto natančno, o spolu in o tem ali živi na podeželju ali v mestu. Poleg tega smo zbrali podatke o tem, koliko časa se ukvarja z glasbo, koliko časa je hodil v glasbeno šolo do leta natančno ter koliko časa na dan posluša glasbo. Tukaj je uporabnik poslušanje glasbe uvrstil v eno od kategorij: do 1 ure, od 1 do 2 uri, od 2 do 3 ure in več kot 3 ure. Imamo tudi podatek o najljubših glasbenih žanrih udeleženca. Udeleženec je podal najmanj en in največ tri žanre. Zanimalo nas je še psihofizično stanje udeleženca med reševanjem. Torej imamo podatek ali jemlje zdravila, ki vplivajo na razpoloženje ter, če je bil v trenutku reševanja pod vplivom drog ali alkohola.

Drugi del podatkovne zbirke vsebuje podatke o udeležencem razpoloženju v trenutku, ko je izpolnjeval anketo in o tem kako si udeleženec predstavlja posamezna razpoloženja. Uporabnikovo razpoloženje opisujejo trije podatki. Prvi je točka v VA prostoru (x in y koordinata). Drugi je barva v barvnem krogu (tukaj hranimo podatek o tem, katero barvo je udeleženec izbral). Tretji pa je vrednost, kako močno je posamezno razpoloženje iz nabora 17 razpoloženj, izraženo pri udeležencu v tistem trenutku. Hranimo vrednost med 0 in 1 za vsako razpoloženje. Kot smo že omenili, drugi del vsebuje tudi podatek o tem, kako si udeleženec predstavlja razpoloženja. Za nabor 10 razpoloženj imamo podatek, kam v VA prostoru spada to razpoloženje po mnenju udeleženca in barvo, s katero ga je udeleženec označil.

Tretji del podatkovne zbirke je malo drugačen. Tu nimamo le enega odgovora na od posameznega udeleženca, ampak do 10 odgovorov, za vsako pesem en odgovor. Imamo podatek o tem, katera razpoloženja so izražena v glasbi in katera razpoloženja glasba vzbudi pri udeležencu. Izbrana razpoloženja je udeleženec umestil v VA prostor, zato imamo tudi podatek, kam v tem prostoru se umeščajo. Za vsako pesem imamo tudi podatek o barvi, s katero je udeleženec označil glasbeni odlomek.

Tabela 3.1: Vprašanja prvega dela ankete. Tabela poleg vprašanj vsebuje še podatke o možnih odgovorih in komentar. V prvem delu ankete smo pridobivali demografske podatke in podatke o uporabnikovih izkušnjah z glasbo.

Vprašanje	Odgovori	Komentar
Starost	[5, 99]	izražena v letih
Spol	{Moški, Ženski}	
Področje prebivanja	{mesto, podeželje}	
Leta glasbenega izobraževanja	[0, 20]	v letih, 0 - pomeni, da se ni glasbeno izobraževal
Igranje instrumenta ali petje	[0, 20]	v letih, 0 - pomeni, da se nikoli ni ukvarjal z glasbo
Uživanje drog	{da, ne}	
Vpliv drog	{da, ne}	Je bil udeleženec pod vplivom drog med reševanjem ankete?
Najljubši žanri	{classical, opera, country, folk, latin, dance/disco, electronic, RnB/soul, hip hop/rap, reggae, pop, rock, alternative, metal, blues, jazz, vocal, easy listening, new age, punk}	Udeleženec je moral izbrati do tri žanre (najmanj enega) in jih razvrstiti od najljubšega do najmanj priljubljenega.
Čas poslušanja glasbe	{manj kot 1, 1-2, 2-3, več kot 3}	v urah na dan

Tabela 3.2: Vprašanja drugega dela ankete. Tabela vsebuje vprašanja, možne odgovore in komentar. Vprašanja sprašujejo po udeležencevem razpoloženju, percepciji oznak za razpoloženje in povezavi med barvami in razpoloženjem.

Vprašanje	Odgovori	Komentar
Trenutno razpoloženje v VA prostoru	VA prostor	Uporabnik je označil razpoloženje v VA prostoru, predstavljenem v poglavju 3.1.2.
Barva razpoloženja	Barvni krog	Uporabnik je izbral barvo trenutnega razpoloženja z barvnim krogom predstavljeni v poglavju 3.1.1.
Percepcija razpoloženja v VA prostoru	{strah, energičnost, jeza, sproščenost, sreča, žalost, živahnost, veselje, razočaranje, nezadovoljstvo}	Uporabniki so umestili razpoloženja v VA prostor z uporabo Mood-Grapha predstavljenega v poglavju 3.1.2
Trenutno razpoloženje z oznakami	{aktivno, budno, dre-mavo, neaktivno, ne-srečno, nezadovoljno, razočarano, sproščeno, srečno, utrujeno, vedro, veselo, zadovoljno, žalostno, mirno, ježno}	Uporabnik je razvrstil vse oznake na Mood-Stripe (predstavljen v poglavju 3.1.2), glede na prisotnost od neizraženega do zelo izraženega.
Barva razpoloženja	{sreča, žalost, nezadovoljstvo, energičnost, razočaranje, veselje, sproščenost, živahnost, strah, jeza}	Za vsako razpoloženje je uporabnik izbral barvo, ki ga najbolj opisuje z uporabo barvnega kroga.

## 3.4 Analiza podatkov

### 3.4.1 Demografska analiza

Povprečna starost udeležencev je 26,5 let. Najmanjši udeleženec je bil star 15 let, najstarejši pa 64 let. Največ udeležencev je bilo starih 20 let. Anketo je rešilo več udeleženk ženskega spola, kar 65%. Večina udeležencev prihaja iz urbanega okolja, 66% udeležencev živi v mestu in 34% na podeželju.


**Ukvarjanje z glasbo** Zanimivo je, da ima kar polovica vseh udeležencev glasbeno izobrazbo, z glasbo pa se ukvarja 53% udeležencev (igrajo inštrument ali pojejo). Udeleženci, ki so obiskovali glasbeno šolo, so jo v povprečju obiskovali 6 let. Tisti, ki se z glasbo ukvarjajo neformalno, se z njo ukvarjajo povprečno 11 let. Pričakovano igranje inštrumenta in petje ter leta glasbene šole zelo visoko korelirata ( $r=0,653$ ). Iz slike 3.7 poleg korelacije razberemo tudi, da se večina ljudi z glasbo ukvarja tudi po dokončani formalni izobrazbi, kar sklepamo iz podatka, da se večina ljudi z glasbo ukvarja dlje, kot traja zgolj formalna izobrazba.

Največ udeležencev posluša glasbo 1 do 2 uri na dan, najmanj pa 2 do 3 ure na dan. Količina poslušanja glasbe ne korelira z nobeno od ostalih demografskih spremenljivk.

**Zdravila in droge** Zdravila, ki vplivajo na razpoloženje, uživa 4,2% udeležencev. Kar 3% udeležencev je poročalo, da so bili med reševanjem ankete pod vplivom drog ali alkohola. Tudi ta dva parametra visoko korelirata med seboj ( $r = 0,519$ ).

**Žanri** Kot je razvidno iz grafa na sliki 3.8, je večina udeležencev kot najljubši žanr označila rock (31,6% udeležencev). Na drugem mestu med najljubšimi žanri je pop z 16,6% in na tretjem alternativna glasba. Na zadnjih dveh mestih sta opera in reggae, ki sta najljubši žanr manj kot odstotku vprašanih. Razporeditev žanrov, ki so jih uporabniki uvrstili na prvo mesto, ni enakomerna, saj kot največkrat izbrana žanra zelo izstopata rock in pop.

Na drugo mesto je spet največ vprašanih uvrstilo rock (20% vprašanih), drugi največkrat uvrščen žanr na drugo mesto je pop z 13,9%. Najmanjkrat izbran žanr




Slika 3.7: Vsaka točka na sliki prikazuje povezavo med trajanjem formalnega glasbenega izobraževanja na vodoravni osi in leta ukvarjanja z glasbo (igranje inštrumenta ali petje) na navpični osi. Iz slike je razvidno, da se večina udeležencev tudi po končani formalni izobrazbi ukvarja z glasbo.

je opera. Na drugem mestu so izbire že bolj raznolike kot pri najljubšem žanru, vendar vrh še vedno izstopa.

Zanimivo je, da je največ udeležencev na tretje mesto uvrstilo klasično glasbo. Za to izbiro se je odločilo 11,9% udeležencev. Klasiki sledi rock (11,3%). Najredkeje so udeleženci na tretje mesto uvrstili new age in punk. Za izbire na tretjem mestu je značilno, da so bolj raznolike, saj noben žanr ne izstopa.


Izmed vseh žanrov smo izbrali najbolj priljubljene: rock, pop, country, alternativna glasba in klasična glasba. Naredili smo primerjavo med najljubšimi žanri po starostnih skupinah (slika 3.9). Udeležence smo razdelili v 6 starostnih skupin. Vsaka od skupin zajema 10 let. Pri vseh starostnih skupinah je popularna rock glasba. Pri najmlajših štirih starostnih skupinah je na prvem mestu. Tudi pop glasba se pojavi pri vseh skupinah razen najstarejših dveh. Razlike se pojavijo v ostalih žanrih. Pri mlajših so popularni še žanri, kot so metal, alternative in elektronska glasba. Pri starejših je zelo popularna klasična glasba, ki se v najstarejših dveh skupinah pojavi na prvem mestu. V teh skupinah so popularne še folk, jazz in



Slika 3.8: Priljubljenost žanrov ter uvrstitev teh na prvo, drugo ali tretje mesto. Razvidno je, da je najbolj priljubljen žanr rock, sledi mu pop in klasična glasba. Najmanj popularen žanr je opera.

country. Srednji dve starostni skupini pa sta kombinacija obojega. V njih se pojavi še alternativna glasba, jazz in klasična glasba.

Naredili smo tudi analizo priljubljenosti glede na spol. Ugotovili smo, da je pri obeh spolih enako zastopana rock glasba. S tem, da pri udeležencih prevladuje še elektronska glasba in metal. Pri udeleženkah pa je na prvem mestu pop glasba.




Slika 3.9: Priljubljenost posameznih glasbenih žanrov po starostnih skupinah. Na vodoravni osi so označene starostne skupine. Širši stolpci predstavljajo razporeditev posameznih žanrov v odstotkih, zeleni pa število udeležencev v posamezni starostni skupini.

### 3.4.2 Razporeženje, čustva in barva

Za ta del analize smo iz podatkovne zbirke odstranili vse, ki so bili pod vplivom drog ali zdravil, ki vplivajo na razporeženje. V anketi smo udeležencevo trenutno razporeženje zajemali na dva načina. Najprej je udeleženec moral označiti svoje razporeženje v VA prostoru. Torej je označeval prijetnost in aktivnost trenutnega razporeženja. Sledila so vprašanja, kjer je udeleženec trenutno razporeženje ocenjeval s tem, da je označil, v kakšni meri je posamezno razporeženje prisotno pri njem. Zanimala nas je predvsem korelacija med prisotnostjo posameznih razporeženj in med koordinatama v VA prostoru. Kot je razvidno iz slike 3.10 je prijetnost (koordinata x) najmanj oddaljena od razporeženj: sproščenost, sreča, zadovoljstvo, vedrost in veselje. Vrednosti predstavljene s y-koordinato se po pričakovanjih najboljše podobne z razporeženjem aktivnost. Prijetnost (predstavljena s x-koordinato) se najmanj ujema s razporeženji nesrečno, nezadovoljno in razočarano, kar je bilo

pričakovati, saj je prijetnost ravno nasprotna s tem razpoloženjem. Z vrednostmi na koordinati y se pričakovano najmanj ujema razpoložene neaktivno zaradi enakega razloga kot pri koordinati x. Opazimo lahko tudi dobro ujemanje med razpoloženji nezadovoljno in razočarano ter med razpoloženji veselo in zadovoljno.




Slika 3.10: Povprečna evklidska razdalja med posamezni atributi. Iz slike je razvidno, da je prijetnost najbolj podobna z razpoloženji: sproščenost, sreča, zadovoljstvo, vedrost in veselje. Aktivnost (koordinata y) se najbolj ujema z razpoloženji aktivno, vedro, veselo in zadovoljno. Opazimo lahko tudi ujemanje med razpoloženji nezadovoljno in razočarano ter veselo in zadovoljno.

Slika 3.11 prikazuje, kako so udeleženci umestili svoje razpoloženje v VA prostor. Opazno je, da so se udeleženci v večjem številu umestili v desno polovico koordinatnega sistema, kar pomeni, da so svoje razpoloženje označili kot bolj prijetno. Več udeležencev občuti bolj neaktivno razpoloženje, kar se odraža v tem, da



je več udeležencev svoje razpoloženje uvrstilo v spodnji del koordinatnega sistema. Največja gostota razpoloženj udeležencev se nahaja v spodnjem desnem kvadrantu, kar pomeni, da se počutijo bolj prijetno in so bolj neaktivni.

Zelo zanimivo je, da s koordinato y korelira starost in tudi poslušanje glasbe. Tisti, ki so starejši, so označili, da se počutijo manj aktivne in obenem manj poslušajo glasbo.



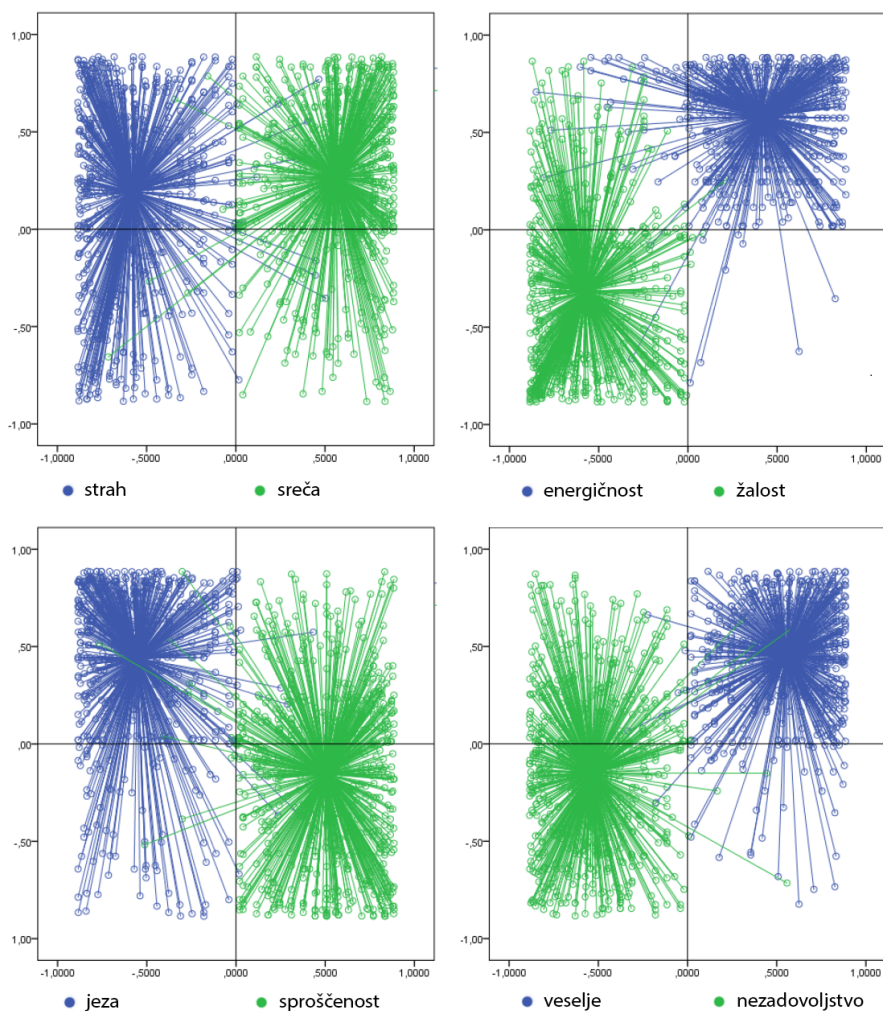
Slika 3.11: Slika prikazuje odgovore vseh uporabnikov o razpoloženju v VA prostoru. Vidi se, da je bilo največ udeležencev v času reševanja ankete prijetnega in neaktivnega razpoloženja.

V anketi smo spraševali tudi o tem, kako uporabniki dojemajo posamezno razpoloženje. Razpoloženje so morali opisati tako, da so posamezno oznako postavili v VA prostor. Na sliki 3.12 je prikazana umestitev 8 razpoloženj v VA prostor.

Slika levo zgoraj prikazuje primerjavo med razpoloženjema strah in sreča. Strah je zelo neprijetno razpoloženje, sreča pa prijetno. Oba sta razporejena praktično preko celotne y osi, kar si lahko razlagamo s tem, da sta to razpoloženji, za katera je težko določiti ali sta aktivni ali ne.

Iz slike desno zgoraj je po pričakovanjih razvidno, da je energičnost zelo prijetno

in aktivno razpoloženje, obenem pa je žalost neprijetna in neaktivna. Zanimivo je, da je kar nekaj udeležencev označilo, da je žalost aktivno razpoloženje.

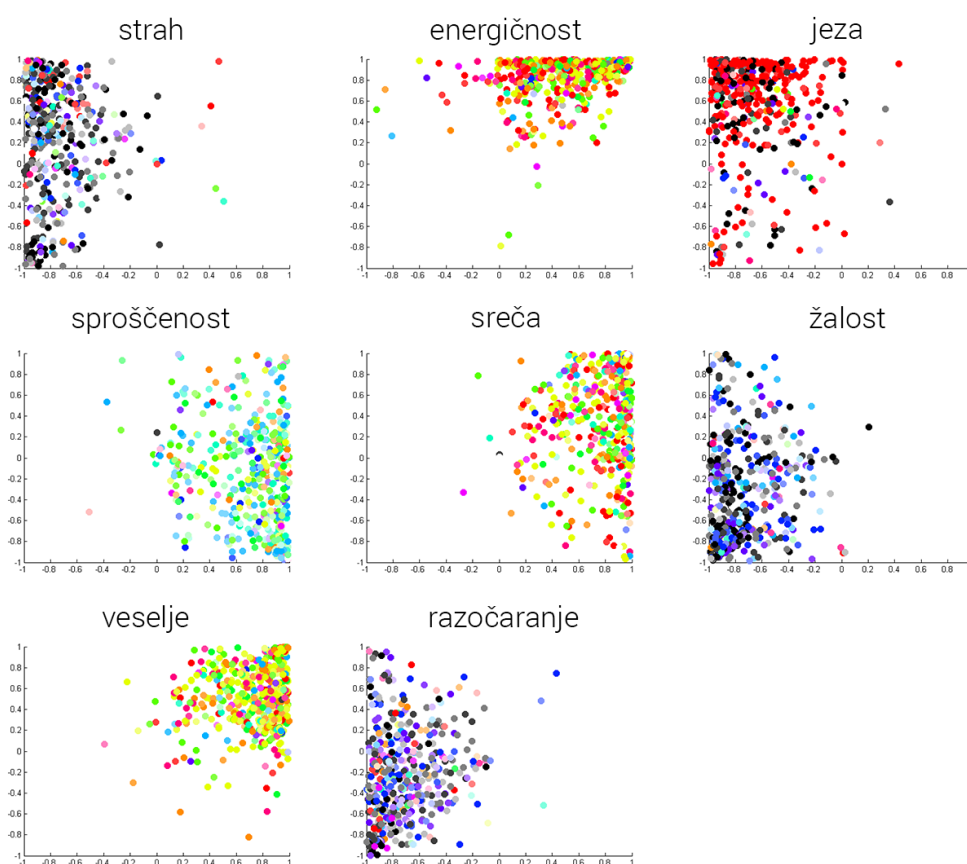


Slika 3.12: V zgornjih VA prostorih je prikazana razporeditev 8 razpoloženj, glede na to, kako so jih v ta prostor uvrstili udeleženci. V splošnem je opazno, da so se udeleženci glede prijetnosti odločili dokaj enotno, medtem ko so večje razlike v aktivnosti.

Na tretjem grafu (levo spodaj) je narejena primerjava med jezo in sproščenostjo. Jeza je po pričakovanjih zelo aktivno in negativno razpoloženje, čeprav je zanimivo,

da nekaj udeležencev meni, da je neaktivna. Sproščenost je prijetna in glede na aktivnost razporejena preko celotnega prostora, čeprav prevladuje mnenje, da je bolj neaktivno razporejena. Tukaj je tudi veliko odgovorov, ki so nevtralni.

Iz četrte slike je razvidno, da je veselje zelo prijetno in aktivno razporejeno, medtem ko je nezadovoljstvo neprijetno. Po aktivnosti je nezadovoljstvo bolj razpršeno, kar govori o tem, da je ta parameter pri tem razporejenju težje določiti.



Slika 3.13: Izbira barv za posamezna razpoloženja in umestitev razpoloženj v VA prostor. Iz slike je razvidno, da so pri prijetnih razpoloženjih izbrane barve manj intenzivne, odtenki so v tem primeru večinoma rdeči, rumeni in zeleni. Pri neprijetnih razpoloženjih so izbrani bolj intenzivni in temnejši odtenki.

**Barva** Ugotovili smo, da obstaja zelo dobra korelacija med barvo in pozicijo razpoloženja v VA prostoru, kar je možno opaziti na sliki 3.13. Pri prijetnih razpoloženjih se barva v večini primerih giblje med rdečo in nežno modro. Pri neprijetnih razpoloženjih so odtenki večinoma modri, črni, rdeči in vijolični. Barve so tu zelo intenzivne.

Iz slike 3.13 je razvidno, da so bili pri strahu pogosto izbrani bolj sivi in črni odtenki. Veselje je bilo v večini primerov označeno z bolj intenzivnimi toni. Odtenki so bili v tem primeru rdeči, oranžni, rumeni ter svetlo zeleni. Pri energičnosti se je večina uporabnikov odločila za rdečo, zeleno in rumeno barvo. Za sproščenost je zanimivo, da je dokaj enakomerno razporejena preko celotnega barvnega spektra. Torej si to razpoloženje vsak udeleženec predstavlja drugače. Intenzivnost barv je pri sproščenosti manjša. Pri jezi je bila pogosto izbrana rdeča, modra ali vijolična barva. Izbirali so praktično med vsemi intenzivnostmi.

### 3.4.3 Glasba, razpoloženje in barva

Za konec smo izbrali še 4 glasbene odlomke in v sliki 3.14 prikazali rezultate. Predstavili smo VA vrednosti, kamor so udeleženci postavili razpoloženja, ki nastopajo v posamezni pesmi. Z krogci so označena mesta kamor so postavili razpoloženja, ki jih po njihovem mnenju glasba vzbudi pri človeku. Z kvadratki so predstavljena razpoloženja, ki jih pesem izraža. Obenem smo vizualizirali tudi barve, ki po mnenju uporabnikov opisujejo posamezno pesem.


Pri prvi pesmi nastopajo razpoloženja, ki so bolj pozitivna in aktivna (večina oznak se nahaja desno zgoraj). Tudi barve so glede na analizo barv zgoraj temu primerne, saj so svetle in niso tako intenzivne, kar se ujema z bolj aktivnimi razpoloženji. Iz grafa se opazi, da ljudje bolj poenoteno dojemajo čustva, ki naj bi jih glasba izražala, manj enotni pa so si v čustvih, ki jih ob poslušanju doživljajo.

Pri drugi pesmi (desno zgoraj) so razpoloženja še vedno bolj prijetna in tudi malo bolj aktivna kot neaktivna. Tudi barve so enako kot pri prejšnji sliki temu primerne. V primerjavi s prejšnjo pesmijo so udeleženci veliko bolj neodločeni glede aktivnosti v pesmi. Tudi pri tej pesmi so izražena razpoloženja manj razpršena in se v večini nahajajo v zgornjem desnem delu grafa za razliko od tistih, ki jih pesem

vzbuja.

Pri pesmi na grafu levo spodaj odločitve niso tako enotne. V večji meri prevladujejo prijetna in obenem aktivna razpoloženja. Je pa zanimivo, da se pojavijo 4 gruča odgovorov. Prva je skrajno levo zgoraj, druga levo spodaj, tretja največja je desno zgoraj in četrta desno spodaj. Odločitve o izraženih razpoloženjih z nekaj izjemami so bolj aktivne, tiste o vzbujenih pa se v večji meri pojavijo tudi v ostalih delih prostora.

Graf za četrto pesem (desno spodaj) je pravo nasprotje vsem ostalim. Notri nastopajo zelo neprijetna razpoloženja, ki so v večini primerov aktivna. Značilno je, da je večina ljudi prijetnost in tudi aktivnost označila na skrajnem robu prostora. V tem primeru so izražena razpoloženja bolj razpršena kot tista, ki jih glasba vzbudi. Tudi barve pri tem grafu so primerne izbranim razpoloženjem, saj so bolj intenzivne in predvsem v rdeče črnih odtenkih.



Slika 3.14: Prikaz razpoloženj v VA prostoru skupaj z barvami, s katerimi so razpoloženja označili uporabniki. S krogi so označena razpoloženja, ki jih po njihovem mnenju glasba vzbudi pri poslušalcu, z kvadrati pa razpoloženja, ki so izražena v glasbi. Narejen je prikaz za 4 pesmi. Nad slikami so označene identifikacijske številke pesmi. Prva pesem je iz zbirke filmske glasbe (identifikacijska številka se začne z 1), druga je iz zbirke etnografskih pesmi (identifikacijska številka se začne z 4), tretja iz zbirke Jamendo (identifikacijska številka se začne z 5) in četrta iz nabora elektro-akustične glasbe (identifikacijska številka se začne z 6).

## Poglavje 4

# Algoritmi za ocenjevanje razpoloženja v glasbi

Zadali smo si, da preizkusimo delovanje nekaterih algoritmov za ocenjevanje razpoloženj v glasbi na naši podatkovni zbirki. V tem poglavju bomo predstavili delovanje in rezultate za regresijski algoritem in algoritem Gaiatransform iz knjižnice Essentia.

### 4.1 Regresijski algoritem

Prvi algoritem, ki smo ga preizkusil je algoritem, ki so ga implementirali Schmidt et al. [24]. Ni nam uspelo dobiti izvirnega algoritma avtorja, ampak smo po informacijah, ki smo jih pridobil ob natančnem pregledu avtorjevega članka in nekaj izmenjanih e-poštah z avtorjem, sami implementiral algoritem, po navodilih avtorja. Algoritem iz glasbe izračuna značilnice. Na podlagi teh potem napove prijetnost (valence) in aktivnost (arousal) v skladbi.

Algoritem za delovanje potrebuje značilnice izračunane na podlagi glasbenih odlomkov. Uporabili smo značilnici MFCC [38] in kromatski vektor [39]. Za računanje teh vrednosti smo uporabili Python knjižnico LibROSA. Poleg tega smo potrebovali še že znane VA vrednosti za del odlomkov, da na podlagi tega učimo algoritem. V našem primeru smo imeli za vse odlomke znane VA vrednosti, tako smo lahko

naključno določili, na katerem delu podatkovne zbirke bomo učili algoritem in na katerem delu testirali. Obenem smo na tak način lahko preverili natančnost naših napovedi. VA vrednosti smo izračunali za vsako pesem s povprečenjem vrednosti v podatkovni zbirki opisani v poglavju 3.

Algoritem deluje, tako da glasbene odlomke naključno razdeli na dva dela. 70% odlomkov uporabi za učenje in ostalih 30% za testiranje. Na delu zbirke za učenje potem uporabi metodo najmanjših kvadratov (Least squares method) [40], s katero izračuna vektor  $b$ , ki ga potem uporabimo za preslikovanje iz matrike z značilnicami v VA vrednosti z enačbo 4.1. Metoda najmanjših kvadratov kot vhod vzame matriko z značilnicami za posamezno pesem in vektor z VA vrednostmi. Ta postopek izvajamo ločeno za prijetnost (valence) in aktivnost (arousal).

$$y = X \cdot b \quad (4.1)$$

V enačbi 4.1 je  $X$  matrika, ki v vsaki vrstici vsebuje značilnice za posamezen glasbeni odlomek,  $b$  je vektor, ki preslikuje iz prostora, ki ga predstavljajo značilnice v VA vrednost. Vrednost, ki jo algoritem napove je  $y$ . Vsaka vrednost predstavlja prijetnost ali aktivnost za en glasbeni odlomek.

#### 4.1.1 Rezultati za regresijski algoritem

Algoritem smo, kot smo že omenili učili z 70% glasbenih odlomkov, test pa smo izvedli na 30% odlomkov.ocene, ki jih je algoritem izračunal na testnih odlomkih, smo potem primerjali s podatki iz podatkovne zbirke.

Rezultati so predstavljeni v tabeli 4.1 za oba tipa značilnic (MFCC in kromatski vektor) posebej. Za vsak primer smo izračunali povprečno razdaljo med povprečno vrednostjo iz podatkovne zbirke in algoritmično napovedano vrednostjo. Prav tako smo izračunali povprečno razdaljo med najbližjo točko v podatkovni zbirki in napovedano vrednostjo. Povprečno razdaljo do povprečne vrednosti smo izrazili tudi v večkratniku standardnega odklona v podatkih iz podatkovne zbirke. Za primerjavo smo algoritem preizkusili tudi na Mood Swing podatkovni zbirki [5].

Rezultati kažejo boljšo korelacijo med MFCC in prijetnostjo (valence) ter aktivnostjo (arousal) v primerjavi z kromatskim vektorjem. Prav tako lahko opazimo, da



Tabela 4.1: Primerjava rezultatov dobljenih z regresijskim algoritmom na naši podatkovni zbirki in Mood Swing podatkovni zbirki z uporabo značilnic MFCC in kromatski vektor. Rezultati so predstavljeni s povprečno razdaljo med povprečno vrednostjo iz podatkovne zbirke in napovedano vrednostjo, s povprečno razdaljo do najbližje vrednosti v podatkovni zbirki in z povprečno razdaljo do povprečne vrednosti merjeno v večkratniku standardnega odklona (standardne deviacije).

Značilnica	MFCC	kromatski vektor
Naša podatkovna zbirka		
Razdalja do povprečne vrednosti	0.2060	0.2215
Razdalja do najbližje vrednosti	0.0595	0.0614
Razdalja do povprečne vrednosti v std. odkl.	0.4870	0.4993
Mood Swing podatkovna zbirka		
Razdalja do povprečne vrednosti	0.2448	0.3316
Razdalja do najbližje vrednosti	0.0641	0.1026
Razdalja do povprečne vrednosti v std. odkl.	0.6514	0.8940

so podatki boljši na naši podatkovni zbirki kot na Mood Swing podatkovni zbirki. Verjetno gre to pripisati predvsem večjemu številu VA vrednosti.

Algoritem smo preizkusil tudi na kromatskem vektorju, izračunanem s hierarhičnim kompozicionalnim modelom, predstavljenim v Pesek et. al [41]. Uporaba te značilnice nam da boljše rezultate, kot jih dobimo z MFCC in kromatskim vektorjem. Na ta način dobljena povprečna razdalja do povprečne vrednosti je 0.1862, razdalja do najbližje vrednosti je 0.0719 in povprečna razdalja merjena v standardnih deviacijah je 0.4459.

V tabeli 4.2 so predstavljene povprečne razdalje izračunane ločeno za prijetnost (valence) in aktivnost (arousal). Iz teh rezultatov je razvidno, da je z uporabo vseh značilnic možno bolj natančno napovedati aktivnost v primerjavi s prijetnostjo. Med tem je možno še opaziti, da kromatski vektor izračunan z Hierarhični


Tabela 4.2: Povprečna razdalja med povprečnimi vrednostmi in napovedmi izračunana ločeno za prijetnost in aktivnost. Razvidno je da so napovedi aktivnosti veliko boljše od napovedi prijetnosti.

	MFCC	Kromatski vektor	HKM kromatski vektor
Prijetnost (valence)	0.1734	0.1826	0.1494
Aktivnost (arousal)	0.0871	0.0940	0.0898

kompozicionalnim modelom da veliko boljše rezultate pri računanju prijetnosti kot ostale značilnice, med tem ko je aktivnost izračunana podobno natančno kot z uporabo MFCC.

Pri postopku ocenjevanja, ki smo ga ponovili 50-krat smo preverili tudi 2% najslabših ocen glede na oddaljenost od povprečne VA vrednosti iz zbirke. Izkaže se, da se te pojavijo le pri 10 glasbenih odlomkih od skupno 200, na katerih smo preizkusili algoritem. Pri nekaterih odlomkih se pojavijo tudi do 10-krat. Po ročnem pregledu glasbenih odlomkov smo ugotovili, da imajo glasbeni odlomki, ki se uvrstijo v 2% najslabših ocen skupno lastnost to, da je pri njih ritem zelo enakomeren, kot je zvonjenje budilke, enakomeren šum ali igranje enega tona z inštrumentom. V njih nastopa na splošno malo različnih tonov. Največ (kar 6) teh odlomkov je iz dela podatkovne zbirke z elektro-akustično glasbo.

Na podlagi značilnic je mogoče zelo dobro oceniti razpoloženje v VA prostoru. Najboljše napovedi da značilnica kromatski vektor izračunan s hierarhičnim kompozicionalnim modelom. Ugotovili smo, da regresijski algoritem natančneje napoveduje aktivnost kot prijetnost, kar kaže na to, da je aktivnost, ali bolj direktno izražena v glasbi, ali jo je mogoče bolje zaznati iz izbranih značilnic. Glede na rezultate bi lahko zaključil, da algoritem, kljub ne najbolj točni napovedi dobro oceni predel prostora v katerem se nahaja razpoloženje. Natančnost bi lahko izboljšali z uporabo kombinacije več značilnic. Z nekaj izboljšavami bi lahko ta algoritem uporabili za ocenjevanje razpoloženja v priporočilnih sistemih.



Slika 4.1: Slika predstavlja 4 VA prostore za pesmi z identifikacijskima številkama 413 (prva vrsta) in 571 (druga vrsta). Kvadrat predstavlja predstavlja povprečno vrednost iz podatkovne zbirke, trikotnik prikazuje napoved algoritma (z uporabo MFCC v prvem stolpcu in kromatskega vektorja v drugem). Pike prikazujejo posamezne vrednosti iz podatkovne zbirke.

## 4.2 Essentia Gaiatransform algoritem

Drugi algoritem, na katerem smo preizkusili natančnost napovedovanja razporeditve na glasbenih odlomkih iz naše podatkovne zbirke, je algoritem GaiaTransform, ki na podlagi nekaterih značilnic izračuna nekatere visoko-nivojske značilnice [27], med katerimi je tudi razporeditve. Algoritem se nahaja v knjižnicah Essentia in Gaia [42].

Essentia je knjižnica namenjena analizi zvoka in predvsem uporabi na področju

MIR. Napisana je v C++ jeziku, možno jo je uporabiti tudi v jeziku Python. Ponuja funkcionalnosti, kot so branje in pisanje zvoka, standardno procesiranje signalov, statistična opredelitev podatkov, izračun velikega števila spektralnih, časovnih, tonskih in ostali značilnic. Te značilnice so osnova za izračun visoko nivojskih značilnic. Essentia skupaj s knjižnico Gaia ponuja funkcionalnosti za izračun nekaterih visoko nivojskih značilnic, kot so žanr, kultura (zahodna ali nezahodna), vrsta plesa na izbrano skladbo, barva zvoka, razpoloženje v skladbi. Ocenjuje tudi, ali je pesem instrumental ali ne. Ker v tem delu preučujemo predvsem razpoloženje v glasbi, se bomo osredotočili na funkcionalnost, ki poskuša odkriti razpoloženje v glasbi.

Algoritem visoko nivojske značilnice izračuna na podlagi nizko nivojskih, ki so prav tako izračunane s knjižnico Essentia. Za določanje visoko nivojskih značilnic seveda ne uporabi vseh značilnic, ampak samo podmnožico teh. To podmnožico so za vsak gručo izračunali posebej z uporabo algoritma za izbiro značilnic na podlagi korelacije (correlationbased feature selection - CFS).

Za klasifikacijo so uporabili večrazredni (muliti-class) SVM algoritem z ena proti ena (one-versus-one) strategijo glasovanja (voting strategy). Uporabili so SVM algoritem iz knjižnice libSVM. Algoritem so razširili z možnostjo napovedovanja verjetnosti prisotnosti določenega razpoloženja (na primer, da pove, da je verjetnost, da v pesmi nastopa sreča 89%). SVM je naučen s petkratnim prečnim preverjanjem.

Algoritem so naučili na 20 različnih glasbenih zbirkah. Algoritem za ocenjevanje razpoloženja iz glasbe so naučili na zbirki, ki so jo pripravili Laurier et. al [43]. Zbirko so potem sami še dodatno označili.

Za razpoloženje algoritem vrne verjetnost, da je v neki pesmi prisotno eno od šestih razpoloženj: srečen (happy), žalosten (sad), agresiven (aggressive), sproščen (relaxed), akustičen (acoustic), elektronski (electronic) in zabaven (party). Poleg tega algoritem glasbeni odlomek glede na razpoloženje razvrsti v eno od 5 gruč (clusters), ki so uporabljene v MIREX opravi (MIREX task). Gruče so definirane z razpoloženji, ki spadajo v posamezno gruči (prikazano v tabeli 4.3).

Tabela 4.3: Gruče razpoloženj, ki se uporabljajo v MIREX mood opraviu.

Gruče	Razpoloženja
Gruča 1	strastno, vznemirjeno, razposajeno
Gruča 2	veselo, zabavno, prijetno, ljubeznivo
Gruča 3	ganljivo, bridko, potrto, otožno, grenko-sladko, malodušno
Gruča 4	šaljivo, duhovito, smešno, neumno, čudaško, muhasto
Gruča 5	agresivno, nasilno, ognjevito, razdražljivo, napeto, intenzivno, nestanovitno, spreminjajoče

### 4.2.1 Natančnost razvrščanja

Zgoraj opisani algoritem po podatkih avtorjev med samostojnimi oznakami za razpoloženje (vesel, žalosten, elektronski, zabaven, sproščen in agresiven) najboljše napoveduje prisotnost agresivnosti z natančnostjo 97,5%. Temu sledijo razpoloženja sproščen (92,92% natančno), zabaven (88,38%), žalosten (86,96%) in elektronski (84,59%). Najslabše napovedi da algoritem za razpoloženje vesel, kjer je natančnost 82,86%.

Tabela 4.4: Natančnost napovedovanja v gruča v odstotkih glede na teste, ki so jih naredili avtorji algoritma. V vrstici so gruča katerim pesem pripada, v stolpcu pa gruča kamor je algoritem uvrsti pesem.

	Gruča 1	Gruča 2	Gruča 3	Gruča 4	Gruča 5
Gruča 1	58,62	18,97	10,34	3,45	8,62
Gruča 2	29,63	48,15	16,67	5,56	0,00
Gruča 3	10,81	13,51	71,62	4,05	0,00
Gruča 4	15,62	43,75	12,50	25,00	3,12
Gruča 5	25,49	1,96	0,00	1,96	70,59

Povsem drugačno je stanje pri natančnosti napovedovanja razpoloženj v gruča. V tem primeru je natančnost le 59.14%. Iz tabele 4.4 je razvidno, da algoritem

najbolj natančno napoveduje gručo 3 in gručo 5, najmanj natančno pa gručo 4. Iz tabele je tudi očitno, da sta gruča 2 in gruča 3 od gručice 5 tako različni, da ni napovedi, ki bi pesem namesto v gručo 2 ali gručo 3 uvrstila v gručo 5. Med tem pa je veliko napačnih preslikav med gručama 1 in 2. Veliko je tudi takšnih napačnih napovedi, ko algoritem pesmi namesto gručice 5 določi gručo 1. Obratna korelacija ni tako močna.

### 4.2.2 Rezultati napovedovanja z algoritmom Gaiatransform

Primerjava rezultatov pri tem algoritmu, je bila malo zahtevnejša kot primerjava z uporabo regresije, saj v naši podatkovni zbirki nimamo enakih oznak, kot jih algoritem vrača kot rezultat. Zaradi tega je bilo potrebno poenotiti oznake. Ugotovili smo, da bo primerjava najlažja, če uporabimo MIREX gručice, ki jih vrača algoritem. Oznake, ki jih imamo v naši podatkovni zbirki, smo razvrstili v gručice glede na podobnost z razpoloženji, ki se nahajajo v teh gručah in so prikazane v poglavju 4.2.1. Razporeditev razpoloženj iz naše podatkovne zbirke v gručice je prikazana v tabeli 4.5. Opaziti je, da v četrto gručo nismo uvrstili nobenega razpoloženja iz naše podatkovne zbirke, ker se nobeno od razpoloženj ne ujema s tistimi na katerih je ta gruča definirana.

Nato smo izvedli primerjavo tako, da smo pogledali katero je najbolj pogosto razpoloženje v podatkovni zbirki pri vsakem izmed 200 glasbenih odlomkov. To razpoloženje smo potem glede na tabelo 4.5 preslikal v gručo. V nadaljevanju smo te gručice primerjali z gručami, ki jih za isti glasbeni odlomek napove algoritem.

Natančnost napovedovanja na naši podatkovni zbirki je 47,50%. Bolj natančni rezultati napovedovanja so prikazani v tabeli 4.6. Vsaka vrstica predstavlja gručo, v katero spada pesem. Stolpci pa predstavljajo gručice, v katere je algoritem uvrstil glasbeni odlomek. Na presečišču je zapisan odstotek elementov uvrščenih v gručo v stolpcu glede na število elementov v dejanski gručici.

Iz teh podatkov je razvidno, da je algoritem najbolj natančno razvrstil elemente v gručo 3, medtem ko je bil najmanj natančen pri določanju gručice 1. Tukaj so rezultati slabi, saj je algoritem večino pesmi iz te gručice uvrstil v gručo 3. Mogoče je

Tabela 4.5: Razvrstitev oznak razpoloženja iz naše zbirke v MIREX gruč glede na podobnost z obstoječimi razpoloženji iz gruč. V četrti gruči ni nobenega razpoloženja, saj se nobeno razpoloženje iz naše zbirke ne ujema z razpoloženji iz te gruče.

Gruča	Razpoloženja
Gruča 1	presenečenje, navdihnjenost
Gruča 2	veselje, sreča, živahnost
Gruča 3	žalost, otožnost, hrepenenje, pričakovanje. sproščenost, mirnost, zasanjanost
Gruča 4	
Gruča 5	jeza, strah

tukaj eden od problemov v tem, da je v tej gruči malo pesmi (7), zato ne moramo posplošiti teh rezultatov. V četrti vrstici so vsi rezultati nič, ker v naši podatkovni zbirki nimamo razpoloženja, za katerega bi lahko rekli, da pripada tej gruči. Tako ni nobene pesmi uvrščene v to gručo. Iz rezultatov lahko opazimo, da je več pesmi, ki so v gruči 5, algoritem uvrstil v gručo 1, kar je podobno rezultatom avtorjev algoritma, ki so prikazani v poglavju 4.2.1. Z avtorjevimi rezultati je podobno tudi to, da odlomki iz gruče 1 niso bili uvrščeni v gručo 4 in to, da je bilo malo odlomkov iz gruče 5 uvrščeno v gručo 2.

Ker se pri določenih pesmih več razpoloženj pojavi skoraj enako pogosto v naši podatkovni zbirki, smo potem primerjavo dopolnili tako, da primerja vsa razpoloženja, ki so blizu razpoloženja, ki se pojavi največkrat. Če je gruča enega od teh razpoloženj enaka gruči, v katero je algoritem uvrstil glasbeni odlomek smatramo napoved kot pravilno.

Pričakovano je bilo, da tak način natančnost napovedovanja poveča. Natančnost pridobljena na tak način znaša 51.5%. Iz rezultatov v tabeli 4.7 je razvidno, da se je natančnost izražena v odstotkih najbolj povečala v prvi gruči, po številu pesmi pa v gruči 5. V gruči 1 so za razliko od prej samo še tiste napačne napovedi, ki se uvrščajo v gručo 3. Odstotek teh se je povečal, ker se je zmanjšalo skupno število

Tabela 4.6: Rezultati napovedovanja v gruče v odstotkih. V vrstici so gruče katerim pesem pripada, v stolpcu pa gruče kamor je algoritem uvrsti pesem. V četrti gruči so ničle, ker se nobeno razpoloženje iz naše zbirke ne ujema z razpoloženji iz te gruče. Zaradi tega tudi nobena pesem ne pripada tej gruči. Najbolj natančne ocene smo dobili za gručo 3, najslabše za gručo 1.

	Gruča 1	Gruča 2	Gruča 3	Gruča 4	Gruča 5	Št. odl.
Gruča 1	14,29	14,29	57,14	0	14,29	7
Gruča 2	12,63	41,05	15,79	9,47	21,05	95
Gruča 3	8,86	25,32	58,22	1,27	6,33	79
Gruča 4	0	0	0	0	0	0
Gruča 5	26,32	5,26	15,79	5,26	47,37	19

pesmi v tej gruči. Ostale napovedi se niso bistveno spremenile.

Kot smo že omenili algoritem poleg klasifikacije v MIREX gruče omogoča ocenjevanje za 6 razpoloženj. Za vsako od razpoloženj napove, če se pojavi v glasbenem odlomku. Glede na to, da se 3 od teh oznak ujemajo z oznakami v naši podatkovni zbirki, sem iz podatkovne zbirke vzel tiste pesmi, kjer je je to razpoloženje najbolj prisotno od vseh. Te pesmi sem potem primerjal z rezultati, ki jih vrne algoritem.

Za ta primer algoritem pravilno napove prisotnost razpoloženja s 79,59% natančnostjo. Kot je razvidno iz tabele 4.8 je natančnost velika pri razpoloženjih žalosten in sproščen. Manjša pa je pri razpoloženju srečen, kar kaže na to, da je algoritmično direktno iz glasbenih odlomkov mnogo lažje napovedati sproščenost in žalost, medtem ko je to težje pri razpoloženju srečen.

Z uporabo algoritma za določanje MIREX gruč iz Essentie smo na naši podatkovni zbirki dobili slabše rezultate, kot so jih dobili avtorji. To gre po vsej verjetnosti pripisati temu, da naše oznake niso enake tistim, ki jih vrača algoritem, pri ročni pretvorbi pa nismo mogli zagotoviti popolnega ujemanja. Zaključimo lahko, da algoritem, ki klasificira v gruče, z okoli 50% natančnostjo še ni najboljši in bi potreboval še izboljšave. Zaradi majhne natančnosti mislimo, da ni dovolj dober za uporabo v priporočilnem sistemu.



Tabela 4.7: Rezultati napovedovanja v gruče v odstotkih v primeru, ko smo upoštevali tudi razpoloženja, ki so blizu največkrat označenem. V vrsticah so gruče, katerim pesem dejansko pripada, v stolpcu pa gruče kamor je algoritem uvrsti pesem. V četrto gručo nismo uvrstili nobene pesmi, zaradi neujemanja vseh naših razpoloženj z razpoloženji v tej gruči. Kot pri tabeli 4.6 so tudi tukaj najboljše napovedi za gručo 3 in najslabše za gručo 1.

	Gruča 1	Gruča 2	Gruča 3	Gruča 4	Gruča 5	Št. odl.
Gruča 1	25	0	75	0	0	4
Gruča 2	12,37	44,33	15,46	9,28	18,56	97
Gruča 3	9,09	22,08	61,04	1,30	6,49	77
Gruča 4	0	0	0	0	0	0
Gruča 5	22,73	4,55	13,64	4,55	54,55	22

Rezultati so v tem primeru, ko napovedujemo posamezno razpoloženje, natančnejši, kot v primeru z ocenjevanjem gruč, zato bi lahko ta način algoritem vključili v priporočilni sistem. Ima pa ta algoritem eno pomanjkljivost, napoveduje le 6 razpoloženj, od katerih so prava razpoloženja le tri. Ostala so bolj lastnosti glasbe, kot razpoloženje.

Tabela 4.8: Natančnost ocenjevanja razpoloženj vesel, žalosten in sproščen v odstotkih. Iz podatkov je razvidno, da algoritem na naši podatkovni zbirki zelo natančno oceni prisotnost razpoloženj žalosten in sproščen, slabši je pri ocenjevanju razpoloženja srečen.

Srečen	54,55
Žalosten	86,36
Sproščen	87,5

## Poglavje 5

# Napovedovanje razpoloženja iz barve

Pri zbiranju podatkovne zbirke smo, poleg razpoloženja, zajemali podatke o tem, s kakšno barvo bi udeleženec opisal razpoloženje v glasbenem odlomku. V poglavju 3.4.2 smo ugotovili, da obstaja povezava med barvami in razpoloženjem. To povezavo smo uporabili za ocenjevanje razpoloženja na podlagi podatkov o barvi. Napovedovali smo prijetnost in aktivnost. Obenem smo preizkusili tudi obratno povezavo, tako da smo ocenjevali barvo posameznega glasbenega odlomka na podlagi podatkov o razpoloženju. Za ocenjevanje razpoloženja iz barve in obratno, smo se odločili, da pokažemo obstoj korelacije med barvami in razpoloženjem v glasbenem odlomku. Ta povezava je koristna za povečanje natančnosti ocenjevanja razpoloženja z algoritmom, ki ga bomo implementirali v prihodnosti in pri vizualizaciji glasbe z barvami.

Za ocenjevanje razpoloženja in barve, smo uporabili regresijski algoritem podoben tistemu, opisanem v poglavju 4.1 z nekaj spremembami. Namesto značilnic smo uporabili podatke o barvi ali podatke o razpoloženju. Algoritem smo izvajali na vseh tipičnih odzivih za izražena razpoloženja v podatkovni zbirki. Tipični odzivi so tisti, ki imajo za glasbeni odlomek samo eno VA oznako. Za izbiro tipičnih odzivov smo se odločili, ker edino pri teh vemo, katero je najbolj značilno razpoloženje za glasbeni odlomek glede na mnenje posameznega udeleženca. Pri odzivih z več izraženimi razpoloženji ni možno določiti, katero je najbolj značilno. Tipičnih odzivov je v naši

podatkovni zbirki 2950, kar je 41% vseh odzivov.

Za preizkus smo pri vsakem odzivu uporabili podatek o barvi zapisani v HSV barvnem prostoru in podatek o razpoloženju zapisanem v VA prostoru. HSV zapis [44] vsebuje tri komponente odtenek (hue - H), intenzivnost (saturation - S) in svetlost (value - V). Barvo iz HSV barvnega modela smo pretvorili tudi v RGB zapis [45] in poskusili ocenjevanje razpoloženja iz tega zapisa. Prav tako smo iz kartezičnih koordinat za razpoloženje izračunali polarne [46] in preizkusili ocenjevanje na teh. Za izbiro polarne koordinatnega sistema smo se odločili, ker smo želeli preveriti, če je boljše na položaj čustva v VA prostoru gledati neodvisno od jakosti izraženega razpoloženja.

## 5.1 Rezultati napovedovanja razpoloženja iz barve

Iz rezultatov v tabeli ?? je razvidno, da je možno dobro napovedati razpoloženje, zapisano v kartezičnih in polarnih koordinatah, iz barve zapisane v HSV barvnem modelu. Opazno je, da je pri napovedovanju razpoloženja v kartezičnem zapisu, veliko lažje oceniti aktivnost kot prijetnost, kar se je izkazalo že pri algoritmu v poglavju 4.1.

Ocene razpoloženja v polarnih koordinatah so natančnejše, kot tiste v kartezičnem koordinatnem sistemu, čeprav na prvi pogled ne zgleda tako. Potrebno je upoštevati, da je obseg ocen v tem primeru drugačen. Če gledamo odmik od povprečne vrednosti v razmerju z obsegom vrednosti opazimo, da je v tem primeru razmerje manjše, kar pomeni bolj točne napovedi. Pri polarnem zapisu je napoved za  $r$  vrednost bolj natančna kot napoved za  $\varphi$ . To pomeni, da lahko bolj natančno napovemo jakost razpoloženja, kot pa aktivnost in prijetnost razpoloženja, kar nekoliko korelira s tem, da v kartezičnem prostoru bolje napovedujemo aktivnost.

Pri ocenjevanju barve iz razpoloženja je razvidno, da so napovedi za HSV barvni model iz kartezičnih koordinat slabe, medtem ko so rezultati z uporabo polarnih koordinat boljši. To se je izkazalo že pri napovedih razpoloženja iz barve. Na podlagi tega lahko sklepamo na boljšo korelacijo med tema komponentama. Napovedi za hue (odtenek) so v obeh primerih boljše kot napovedi za value (svetlost), med tem ko so rezultati za saturation (intenzivnost) tako naključni, da so v tabeli izpušeni.

Preizkusili smo tudi napovedovanje RGB vrednosti za barvo iz razpoloženja in razpoloženje iz RGB vrednosti, vendar se je izkazalo, da so napovedi slabše, kot pri HSV barvnem modelu.

Tabela 5.1: Rezultati natančnosti ocenjevanja razpoloženja iz barve in barve iz razpoloženja z regresijskim algoritmom. Prikazni so le rezultati, ki kažejo določeno povezavo. Tam kjer ni povezave so vrednosti zelo naključne. Prikazana je povprečna razdalja do povprečnih vrednosti za posamezno pesem v zbirki.  $VA_{x,y}$  je oznaka za razpoloženje v VA prostoru zapisano s kartezičnimi koordinatami,  $VA_{r,\varphi}$  je zapis za razpoloženje v VA prostoru zapisano s polarnimi koordinatami. Podatkom je dodan obseg vrednosti ocenjenega parametra, da si lahko predstavljamo natančnost ocen.

Način napovedovanja	Povprečna razdalja	Obseg vrednosti
Ocenjevanje HSV iz $VA_{x,y}$	hue: 0.2697 value: 0.6486	hue: $[0, 1]$ value: $[0,1]$
Ocenjevanje $VA_{x,y}$ iz HSV	valence: 0.2000 arousal: 0.1279	valence: $[-1, 1]$ arousal: $[-1,1]$
Ocenjevanje HSV iz $VA_{r,\varphi}$	hue: 0.1431 value: 0.3215	hue: $[0, 1]$ value: $[0,1]$
Ocenjevanje $VA_{r,\varphi}$ iz HSV	r: 0.1083 $\varphi$ : 0.3092	r: $[0, \sqrt{2}]$ $\varphi$ : $[0, 2\pi]$

Če podatke primerjamo z ocenami na podlagi značilnic MFCC in kromatski vektor ugotovimo, da so nekatere ocene skoraj tako dobre, kot tiste predstavljene v poglavju 4.1. Razdalja od povprečja pri ocenah razpoloženja, izračunanih na podlagi barve zapisane v HSV barvnem modelu, se pri valence komponenti s tisto izračunano na podlagi kromatskega vektorja razlikuje za manj kot 0,02, pri aktivnosti je večja le za 0,03. V primerjavi z ocenami za MFCC in HKM kromatski vektor, je razlika malo večja. Prav tako opazimo podobnost v natančnosti ocen za prijetnost in aktivnost. V obeh primerih algoritem veliko lažje oceni aktivnost, kot prijetnost.

Ugotovili smo, da je mogoče na podlagi podatka o barvi z razmeroma dobro natančnostjo oceniti razpoloženje v primerjavi z ocenami na podlagi značilnic. To nam odpira možnosti za izboljšanje algoritmov za ocenjevanje čustev iz glasbe z dodatnimi parametri, ki niso pridobljeni direktno iz glasbe, v tem primeru na podlagi barve. Prav tako je pomembna obratna povezava. Na podlagi razpoloženja je mogoče dobro oceniti odtenek v barvnem prostoru HSV. Čeprav je ta napoved slabša od tiste za razpoloženje, nam pove pravi odtenek ali zelo sorodnega, saj so v HSV barvnem prostoru podobni odtenki glede na vrednost parametra hue blizu skupaj. Ta podatek nam koristi pri vizualizaciji glasbe z barvami.

## Poglavje 6

# Zaključek in nadaljnje delo

Z uporabo spletne ankete smo zbrali podatkovno zbirko, ki vključuje veliko število odgovorov in bo kmalu javno objavljena. Podatkovna zbirka vključuje udeleženceve demografske podatke, podatke o njegovi percepciji razpoloženja v VA prostoru in barv ter veliko razpoloženskih in barvnih oznak za glasbene odlomke. Ti vključujejo razpoloženja, ki jih glasba vzbudi pri udeležencu in razpoloženja, ki se po udeležencevem mnenju pojavijo v glasbenem odlomku skupaj z VA vrednostmi. Vsak odgovor vsebuje tudi podatek o barvi, ki po udeležencevem mnenju najboljše opisujejo razpoloženje v glasbenem odlomku. Za razliko od nekaterih ostalih podatkovnih zbirk naša vključuje tudi glasbene odlomke. Ta podatkovna zbirka odpira nove možnosti za raziskovanje ocenjevanja čustev iz glasbe.

Uporabili smo dva algoritma za ocenjevanje čustev iz glasbe. Prvi je regresijski algoritem, ki napoveduje prijetnost in aktivnost na podlagi značilnic MFCC in kromatski vektor. Najboljše rezultate dobimo, če uporabimo kromatski vektor izračunan s hierarhičnim kompozicionalnim modelom [41]. Ugotovili smo tudi, da je aktivnost možno napovedati z večjo natančnostjo kot prijetnost. Drugi algoritem je Gaiatransform, ki glasbene odlomke, glede na razpoloženje, klasificira v 5 gruč določenih s strani MIREX-a. Algoritem na naši podatkovni zbirki ocenjuje razpoloženje s približno polovično natančnostjo. Z največjo natančnostjo klasificira v gručo 3, ki vsebuje razpoloženja: žalost, otožnost, hrepenenje, pričakovanje, sproščenost, mirnost in zasanjanost. Najslabše klasificira v gručo 1 z razpoloženji

presenečenje in navdihnjenost. Poleg kasifikacije v gruče algoritem ocenjuje pristnost razpoloženj sreča, žalost in sproščenost, kjer prisotnost razpoloženja sproščenost na naši zbirki ocenjuje z 87,5% natančnostjo. Zelo dobro ocenjuje tudi pristnost razpoloženja žalost, pri sreči so rezultati slabši.

Za konec smo preizkusili še uporabnost ostalih podatkov iz zbirke. Preizkusili smo natančnost ocenjevanja razpoloženja na podlagi barve za glasbene odlomke iz zbirke in obratno. Izkazalo se je, da je možno na podlagi HSV zapisa za barvo zelo dobro napovedati razpoloženje, pri čemer z večjo natančnostjo ocenimo aktivnost. Možno je tudi dobro oceniti hue komponento za barvo na podlagi polarnega zapisa koordinat za VA vrednost.

Ocenjevanje čustev iz glasbe je pomembna osnova za različna opravila vključujoč priporočilne sisteme za glasbo na podlagi razpoloženja. Udeleženci podatki v naši podatkovni zbirki prinesejo nove možnosti za raziskovanje uporabnosti teh podatkov v priporočilnih sistemih.

Kmalu bomo začeli z izvajanjem drugega kroga ankete, ki bo izvedena tudi v angleškem jeziku. Vsebovala bo dodatno zbirko glasbenih odlomkov. S tem želimo povečati število odgovorov na glasbeni odlomek in povečati število odlomkov v podatkovni zbirki. Pridobljeni podatki nam bodo dali možnost primerjave podatkov med udeleženci, ki govorijo slovensko in ostalimi. Nadaljevali bomo s testiranjem algoritmov za ocenjevanje čustev iz glasbe. Načrtujemo razviti novo metodo za ocenjevanje čustev iz glasbe, ki bo upoštevala tudi demografske in ostale podatke iz zbirke.

V nadaljevanju bomo še bolj raziskali povezavo med razpoloženjem in barvami. Načrtujemo narediti vizualizacijo za podlagi rezultatov te raziskave. Vizualizacija bo uporabljena v vmesniku priporočilnega sistema na podlagi razpoloženja, ki ga nameravamo razviti.



# Literatura

- [1] Jin Chun Lee Jae Sik Lee. Music for My Mood: A Music Recommendation System Based on Context Reasoning. In Paul Havinga, Maria Lijding, Nirvana Meratnia, and Maarten Wegdam, editors, *Smart Sensing and Context*, volume 4272 of *Lecture Notes in Computer Science*, pages 190–203. Springer Berlin Heidelberg, Berlin, Heidelberg, 2006.
- [2] Y Song, S Dixon, and M Pearce. A survey of music recommendation systems and future perspectives. In *Proc. 9th Int. Symp. Computer Music Modelling and Retrieval (CMMR)*, pages 395–410, London, 2012.
- [3] Hung-Chen Chen and Arbee L P Chen. A music recommendation system based on music data grouping and user interests. In *Proceedings of the tenth international conference on Information and knowledge management*, pages 231–238. ACM, 2001.
- [4] T Eerola and J K Vuoskoski. A comparison of the discrete and dimensional models of emotion in music. *Psychology of Music*, 39(1):18–49, 2010.
- [5] Erik M Schmidt and Youngmoo E Kim. Modeling Musical Emotion Dynamics with Conditional Random Fields. In *Proceedings of the International Conference on Music Information Retrieval (ISMIR)*, pages 777–782, 2011.
- [6] Douglas Turnbull, Luke Barrington, David Torres, and Gert Lanckriet. Semantic annotation and retrieval of music and sound effects. *Audio, Speech, and Language Processing, IEEE Transactions on*, 16(2):467–476, 2008.

- 
- [7] Björn Schuller, Clemens Hage, Dagmar Schuller, and Gerhard Rigoll. ‘Mister DJ, Cheer Me Up!’: Musical and textual features for automatic mood classification. *Journal of New Music Research*, 39(1):13–34, 2010.
  - [8] R Panda, R Malheiro, B Rocha, A Oliveira, and R P Paiva. Multi-Modal Music Emotion Recognition: A New Dataset, Methodology and Comparative Analysis. *Proc. CMMR*, 2013.
  - [9] Bernie Krause. Echonest of the past. In *The Great Animal Orchestra: Finding the Origins of Music in the World’s Wild Places*, chapter Echonest o, pages 5–10. Hachette Digital, Inc., London, 2012.
  - [10] Mira Lenko, Tina Kogovšek, and Peter Stanković. *Pomen glasbe v očeh mladih: diplomsko delo*. M. Lenko, 2009.
  - [11] Matevž Pesek. *Prepoznavanje akordov s hierarhičnim kompozicionalnim modelom: diplomsko delo*. PhD thesis, M. Pesek, 2012.
  - [12] J Stephen Downie. The music information retrieval evaluation exchange (2005–2007): A window into music information retrieval research. *Acoustical Science and Technology*, 29(4):247–255, 2008.
  - [13] J Stephen Downie, Andreas F Ehmann, Mert Bay, and M Cameron Jones. The Music Information Retrieval Evaluation eXchange: Some Observations and Insights. In Wierzchowska A.A. and Ras Z.W., editors, *Advances in Music Information Retrieval*, pages 93–115. Springer-Verlag, Berlin, 2010.
  - [14] Jiajun Bu, Shulong Tan, Chun Chen, Can Wang, Hao Wu, Lijun Zhang, and Xiaofei He. Music recommendation by unified hypergraph: combining social media information and music content. In *Proceedings of the international conference on Multimedia*, pages 391–400. ACM, 2010.
  - [15] Pasi Saari, Tuomas Eerola, György Fazekas, Mathieu Barthet, Olivier Lartillot, and Mark B Sandler. The Role of Audio and Tags in Music Mood Prediction: A Study Using Semantic Layer Projection. In *Proceedings of the International Conference on Music Information Retrieval (ISMIR)*, pages 201–206, 2013.

- 
- [16] O. Gillet and G. Richard. Transcription and Separation of Drum Signals From Polyphonic Music. *IEEE Transactions on Audio, Speech, and Language Processing*, 16(3):529–540, March 2008.
  - [17] Yipeng Li and DeLiang Wang. Separation of Singing Voice From Music Accompaniment for Monaural Recordings. *IEEE Transactions on Audio, Speech and Language Processing*, 15(4):1475–1487, May 2007.
  - [18] David Gerhard. Pitch Extraction and Fundamental Frequency: History and Current Techniques. Technical report, University of Regina, Saskatchewan, Canada, Regina, 2003.
  - [19] Anssi Klapuri and Manuel Davy, editors. *Signal Processing Methods for Music Transcription*. Springer, New York, 2006.
  - [20] Anssi P Klapuri. Automatic Music Transcription as We Know it Today. *Journal of New Music Research*, 33(3):269–282, September 2004.
  - [21] Dave Smith and Chet Wood. MIDI Musical Instrument Digital Interface Specification 1.0, 1983.
  - [22] Asa Ben-Hur and Jason Weston. A user’s guide to support vector machines. In *Data mining techniques for the life sciences*, pages 223–239. Springer, 2010.
  - [23] Wei-rong Chu, RT-H Tsai, Ying-Sian Wu, Hui-Hsin Wu, Hung-Yi Chen, and JY-J Hsu. LAMP, a lyrics and audio mandopop dataset for music mood estimation: Dataset compilation, system construction, and testing. In *Technologies and Applications of Artificial Intelligence (TAAI), 2010 International Conference on*, pages 53–59. IEEE, 2010.
  - [24] Erik M Schmidt and Youngmoo E Kim. Projection of acoustic features to continuous valence-arousal mood labels via regression. In *10th International Society for Music Information Retrieval Conference. ISMIR*, 2009.
  - [25] Cyril Laurier, Perfecto Herrera, M Mandel, and D Ellis. Audio music mood classification using support vector machine. *Music Information Retrieval Evaluation eXchange (MIREX) extended abstract*, 2007.

- 
- [26] Diane Watson and Regan L Mandryk. Modeling Musical Mood From Audio Features and Listening Context on an In-Situ Data Set. In *Proceedings of the International Conference on Music Information Retrieval (ISMIR)*, pages 31–36, 2012.
  - [27] D Bogdanov. *From music similarity to music recommendation: Computational approaches based on audio features and metadata*. PhD thesis, Universitat Pompeu Fabra, Barcelona, Spain, 2013.
  - [28] Rabiner Lawrence. *Fundamentals of speech Recognition*. Pearson Education India, 2008.
  - [29] Fabien Gouyon and Perfecto Herrera. Exploration of techniques for automatic labeling of audio drum tracks instruments. In *Proceedings of MOSART: Workshop on Current Directions in Computer Music*, 2001.
  - [30] Paul Brossier, Juan Pablo Bello, and Mark D Plumbley. Real-time temporal segmentation of note objects in music signals. In *Proceedings of the ICMC*, 2004.
  - [31] F Gouyon, O Delerue, and F Pachet. Classifying percussive sounds: a matter of zero-crossing rate? In *Proceedings of the COST G-6 Conference on Digital Audio Effects*, 2000.
  - [32] Yongwei Zhu, Mohan S Kankanhalli, and Sheng Gao. Music key detection for musical audio. In *Multimedia Modelling Conference, 2005. MMM 2005. Proceedings of the 11th International*, pages 30–37. IEEE, 2005.
  - [33] Ernst Terhardt. Pitch, consonance, and harmony. *The Journal of the Acoustical Society of America*, 55(5):1061–1069, 1974.
  - [34] Jan La Rue. Harmonic Rhythm in the Beethoven symphonies. *The Journal of Musicology*, 18(2):221–248, 2001.
  - [35] Tim Dalgleish and Michael J Power. Basic Emotions. In *Handbook of cognition and emotion*. Wiley Online Library, 1999.

- 
- [36] B Wu, S Wun, C Lee, and A Horner. Spectral correlates in emotion labeling of sustained musical instrument tones. In *Proceedings of the International Conference on Music Information Retrieval (ISMIR)*, pages 415–421, 2013.
- [37] Tiziano Colibazzi, Jonathan Posner, Zhishun Wang, Daniel Gorman, Andrew Gerber, Shan Yu, Hongtu Zhu, Alayar Kangarlu, Yunsuo Duan, James A Russell, and Bradley S Peterson. Neural systems subserving valence and arousal during the experience of induced emotions. *Emotion (Washington, D.C.)*, 10(3):377–389, 2010.
- [38] Beth Logan and Others. Mel Frequency Cepstral Coefficients for Music Modeling. In *ISMIR*, 2000.
- [39] Juan P Bello and Jeremy Pickens. A robust mid-level representation for harmonic content in music signals. In *Proceedings of the International Conference on Music Information Retrieval (ISMIR)*, pages 304–311, London, 2005.
- [40] Hervé Abdi. The method of least squares. *Encyclopedia of Measurement and Statistics*. CA, USA: Thousand Oaks, 2007.
- [41] Matevž Pesek and Matija Marolt. Chord estimation using compositional hierarchical model. In *6th International Workshop on Machine Learning and Music, held in conjunction with the European Conference on Machine Learning and Principles and Practice of Knowledge Discovery in Databases, ECML/PKDD 2013*, 2013.
- [42] Dmitry Bogdanov, Nicolas Wack, Emilia Gómez, Sankalp Gulati, Perfecto Herrera, Oscar Mayor, Gerard Roma, Justin Salamon, José R Zapata, and Xavier Serra. Essentia: An Audio Analysis Library for Music Information Retrieval. In *Proceedings of the International Conference on Music Information Retrieval (ISMIR)*, pages 493–498. Citeseer, 2013.
- [43] Cyril Laurier, Owen Meyers, Joan Serrà, Martin Blech, Perfecto Herrera, and Xavier Serra. Indexing music by mood: design and integration of an automatic content-based annotator. *Multimedia Tools and Applications*, 48(1):161–184, 2009.

- [44] S. Sural and S. Pramanik. Segmentation and histogram generation using the HSV color space for image retrieval. In *Proceedings. International Conference on Image Processing*, volume 2, pages II-589–II-592. IEEE, 2002.
- [45] Sabine Süsstrunk, Robert Buckley, and Steve Swen. Standard RGB color spaces. In *Color and Imaging Conference*, volume 1999, pages 127–134. Society for Imaging Science and Technology, 1999.
- [46] Simon J Julier and Jeffrey K Uhlmann. Consistent debiased method for converting between polar and Cartesian coordinate systems. In *AeroSense'97*, pages 110–121. International Society for Optics and Photonics, 1997.